

STŘEDOŠKOLSKÁ ODBORNÁ ČINNOST

Obor č. číslo oboru: Název oboru

(červeně psané věci přepište podle skutečnosti a změňte jejich barvu na černo.
Toto doporučení vymažte)

Plný název práce v češtině

Jméno autora/autorky/autorů

Oficiální název kraje

Město a vročení

STŘEDOŠKOLSKÁ ODBORNÁ ČINNOST

Obor č. číslo oboru: Název oboru

Plný název práce v češtině

Plný název práce v angličtině

Autoři: Jméno autora/autorky/autorů

Škola: Oficiální název, ulice č. p., PSČ město

Kraj: Oficiální název kraje

Konzultant: Jméno a příjmení konzultantů včetně všech titulů

Město a vročení

Prohlášení

Prohlašuji, že jsem svou práci SOČ vypracoval/a samostatně a použil/a jsem pouze prameny a literaturu uvedené v seznamu bibliografických záznamů.

Prohlašuji, že tištěná verze a elektronická verze soutěžní práce SOČ jsou shodné.

Nemám závažný důvod proti zpřístupňování této práce v souladu se zákonem č. 121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon) ve znění pozdějších předpisů.

V město dne datum

Jméno a Příjmení autora (totéž pro všechny autory)

Poděkování

Na tomto místě můžete vložit poděkování těm, kteří vám s tvorbou práce SOČ pomohli. Poděkování je vaše autorské dílo, nemá předepsanou podobu a není povinnou součástí práce SOČ. Záleží jen na vás, zda, komu a jakým způsobem poděkuujete

Anotace

Tato práce se zabývala možnostmi využití umělé inteligence ke klasifikování skupin slunečních skvrn. Hlavní náplní práce bylo vytvořit model konvoluční neuronové sítě schopný rozřadit skupiny slunečních skvrn podle McIntoshovy klasifikace. Vstupní data tvořily upravené kresby Slunce kreslené na Ondřejovské hvězdárně. Jako programovací jazyk byl vybrán Python. Podařilo se vytvořit dva různě fungující modely schopné predikovat klasifikaci skupiny. Taktéž bylo dokázáno, že lze natrénovat umělou inteligenci ke klasifikování skupin slunečních skvrn. K vytvoření lepších modelů by bylo potřeba více vstupních dat, například více kreseb z jiných, zahraničních hvězdáren.

Klíčová slova

sluneční skvrny; umělá inteligence; konvoluční neuronové sítě; McIntoshova klasifikace; sluneční kresba

Annotation

Překlad anotace do anglického jazyka

Keywords

Překlad klíčových slov do anglického jazyka

Obsah

1	Úvod	7
2	Slunce	8
2.1	Vrstvy Slunce	8
3	Sluneční skvrny	9
3.1	Schwabeův sluneční cyklus.....	9
3.2	Tvorba slunečních skvrn	10
3.3	Skupiny skvrn	11
3.3.1	Polarita skupin	11
3.3.2	Relativní číslo	11
3.4	Klasifikace aktivní oblasti.....	12
3.4.1	Curyšská klasifikace	12
3.4.2	McIntoshova klasifikace	13
3.4.3	Mount Wilson klasifikace	15
3.5	Kresba Slunce	15
3.5.1	Postup kresby.....	16
3.5.2	Informace v protokolu	16
4	Strojové učení	18
4.1	Neuronové sítě	19
4.1.1	Konvoluční neuronové síť	22
4.2	Nástroje strojového učení.....	22
4.2.1	Programovací jazyk Python	23
4.2.2	Knihovny TensorFlow a Keras	23
4.2.3	Editor Visual Studio Code	23
4.2.4	Systém Git a GitHub.....	23
5	Klasifikace slunečních skvrn pomocí AI	24
5.1	Vstupní data	24
5.1.1	Úprava vstupní kresby	25
5.2	Detekce čtyřúhelníků	25
5.3	Rozřazení dat podle klasifikace	26
5.4	Příprava dat na trénování	27
5.5	Architektura modelu.....	28
6	Výsledky práce	29

6.1	Klasifikace do dvou tříd	29
6.1.1	Model Axx-Dai	29
6.1.2	Model Axx-Bxo	30
6.2	Klasifikace do čtyř tříd	31
6.2.1	Model Axx-Csi-Eac-Hsx	31
6.2.2	Model Axx-Bxi-Cso-Cai	32
6.3	Klasifikace podle písmen	33
6.3.1	Model A-B-C-DEF-H	35
6.3.2	Model x-r-sh-ak	36
6.3.3	Model x-o-i-c	37
6.4	Finální model písmen	37
6.5	Finální model skupin	33
7	Závěr	37
7.1	Diskuze	38
7.2	IMPLEMENTACE HVĚZDÁRNAMI	38
7.3	Chyby	38
8	tvorba SS	38
8.1	Nadpis 2. úrovně: Times New Roman, 16 b, tučný, mezera za 16 b	40
8.1.1	Nadpis 3. úrovně: Times New Roman, 14 b, tučný, mezera za 14 b	40
8.2	Parametry jednotlivých stylů	40
8.3	Způsob citování	41
8.3.1	Odkazování v textu	41
8.3.2	Bibliografický záznam	42
8.4	Rozsah práce	42
9	Závěr	42
10	Použitá literatura	43
11	Seznam obrázků a tabulek	47
12	Příloha 1: Název přílohy	49

1 ÚVOD

Hlavním motivem této práce bylo prozkoumat možnost využití umělé inteligence ve sluneční astronomii, konkrétně při klasifikaci slunečních skvrn. Pojem umělá inteligence se hlavně s rozvojem chatovacích robotů a programů generující obrázky dostal do všeobecného povědomí a mnohdy je tento termín špatně vykládán a používán. Zároveň je tendence začít využívat tyto nové nástroje v různých odvětvích a tato práce by měla poskytnout *proof of concept* toho, že lze zapojit strojové učení i na hvězdárnách.

Druhým cílem bylo dokázat, že lze vytvořit model strojového učení, který by byl schopen s určitou přesností predikovat zařazení aktivní oblasti podle McIntoshova klasifikačního systému. Tento model by byl vytvořen na základě slunečních kreseb, které obsahují zakreslené skupiny skvrn. Tento model by pak personál, který klasifikaci provádí, mohl použít ke kontrole svých pozorování. Práce by měla poskytnout jednoduchý a vystihující návod, jak připravit vstupní data vhodná k natrénování modelu, jak správně nastavit parametry neuronové sítě a jak správně určit přesnost těchto modelů.

V neposlední řadě bylo cílem práce také poskytnout text, který by jednoduše a od základů spojoval oba tematické okruhy, jak sluneční astronomii, tak i strojové učení. První kapitoly by měly shrnovat informace, které by čtenář měl vědět, pokud chce taktéž vytvořit klasifikační model. Kapitoly by měly shrnovat důležitá a obecná fakta o Slunce, věnovat se slunečním skvrnám, klasifikaci jejich skupin i kresbě samotné (například poskytnout návod, jak takou kresbu vytvořit) a také vpravit čtenáře do problematiky práce ze strany informatiky, umělé inteligence, strojového učení i konvolučních neuronových sítí.

Kromě toho, že téma propojuje dvě zajímavé oblasti vědy, jsme zaměření práce zvolili z důvodu zpopularizování kresby Slunce. Systematické pozorování Slunce pomocí jeho zakreslení je celosvětově prováděno již přes tři staletí, ale i tak existuje pouze malé množství českých hvězdáren, které Slunce takto pravidelně zaznamenávají. Jednou z těchto institucí je i Ondřejovská hvězdárna, která poskytuje nepřeberné množství svých kresby volně ke stažení. V Ondřejově má sluneční pozorování velmi dlouhou tradici, svědčí o tom i fakt, že první volně dostupná kresba je již z roku 1944. Ovšem v archivu hvězdárny se najdou kousky z dob 2. světové války zachycené na fotografickou desku. Mohlo by být namítnuto, že kreslení Slunce je v nynější moderní době plné digitálních fotoaparátů a družic zbytečné, ale zasvěcení odborníci by jistě odporovali. Dodržovaní téměř nepřetržité řady pozorování od 17. století dělá z kresby v podstatě nejdéle běžící fyzikální experiment a zároveň pouze díky srovnání kresby a dat z družic lze lépe chápat, co se dělo se Sluncem v době, kdy tyto technologie ještě nebyly. Součástí práce bylo i navštívení Ondřejovské hvězdárny.

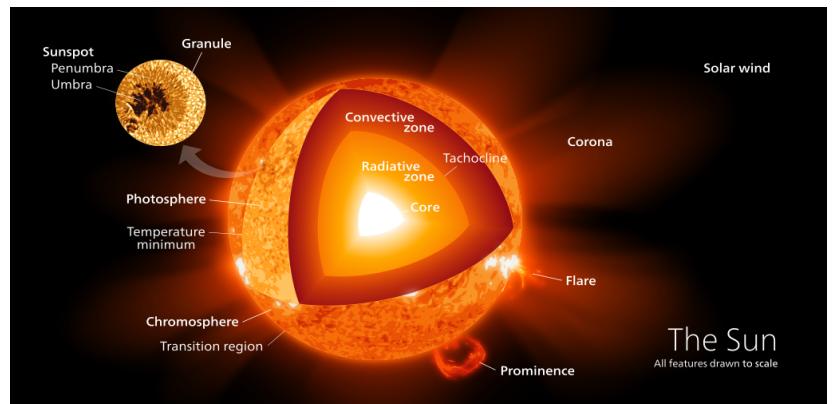
2 SLUNCE

Je jistě všeobecně známo, že Slunce je naši nejbližší hvězdou. Slunce je od nás vzdáleno přibližně sto padesát milionu kilometrů¹ a jeho průměr činí přibližně jeden a čtyři desetiny milionu kilometrů². Kombinací obou hodnot lze získat úhlový průměr slunečního disku kolem 31,5', tedy takový, jaký má palec na natažené ruce. Díky takovému velkému průměru se mohou pomocí dalekohledů, družic a dalších zařízení velmi dobře zkoumat i velmi malé detaily, díky kterým lze lépe detailně pochopit sluneční aktivitu. Jedním z projevů sluneční aktivity jsou sluneční skvrny. Dalšími jsou erupce, protuberance, filamenty, granulace slunečního povrchu a mnohé další.

2.1 Vrstvy Slunce

Stejně jako Země má různé vrstvy, termosféru, kůru, jádro, tak i Slunce lze rozčlenit na podobné vrstvy, viz Obrázek 1.

Ve středu Slunce se nachází jádro, kde dochází ke slučování vodíku na helium a generování zářivé energie. Dále se nachází vrstva zářivé rovnováhy, kde se energie z jádra dostává na povrch postupným pohlcováním a opětovným vyzařování. [3] Další vrstva se nazývá konvektivní vrstva. Zde se energie přesouvá prouděním plazmatu, nikoliv pohlcením a vyzářením. Mezi těmito dvěma vrstvami se ještě vyskytuje relativně nově objevená slupka, tachoklina. Její tloušťka je asi 0,04 poloměru Slunce a podle posledních poznatků dochází ke generování magnetického pole právě zde, a to vlivem rozdílné rotace vrstvy zářivé rovnováhy, která rotuje spíše jako pevné těleso, a konvektivní zóny, jejíž rotace by se spíše přirovnala k rotaci tekuté látky.



Obrázek 1: Vrstvy Slunce [4]

První vrstvou atmosféry Slunce je fotosféra. V této vrstvě lze pozorovat granulaci povrchu nebo sluneční skvrny. [5] Další vrstvou je chromosféra, zde například vznikají erupce a protuberance. Poslední vrstva sluneční atmosféry se nazývá koróna. Ta sahá miliony kilometrů do kosmického prostoru a vytváří se v ní koronální díry a kondenzace.

¹ Se vzdáleností mezi Sluncem a Zemí úzce souvisí astronomická jednotka, což je jednotka vzdálenosti používaná v astronomii. Její hodnota je definována na 1 au = 149 597 870 700 m [1] a tato vzdálenost přibližně odpovídá vzdálenosti Země od Slunce

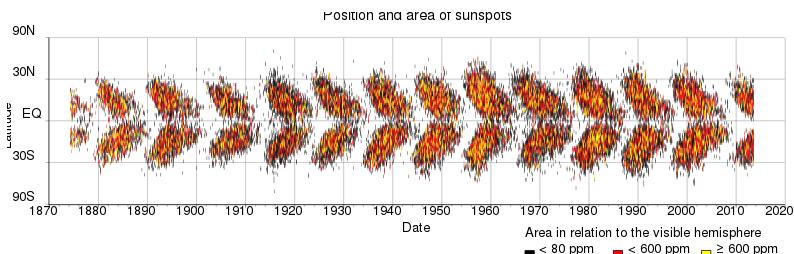
² Přesná hodnota slunečního poloměru je pak 695 700 km [2].

3 SLUNEČNÍ SKVRNY

Sluneční skvrny jsou tmavé útvary vyskytující se na Slunci. První písemný zápis o jejich pozorování se dochoval z doby před naším letopočtem a pochází z Asie. [6][7] Aktivně začaly být skvrny pozorovány až s vynálezem dalekohledu v 17. století. Sluneční skvrny jsou místem ve fotosféře Slunce, kde vystupují magnetické indukční čáry na povrch, a jsou pozorovatelné ve viditelném spektru, viz Obrázek 2.

Sluneční skvrny se mohou navzájem velmi odlišovat, a to jak velikostí, tak tvarem i rozložením v prostoru, což z nich dělá věc vhodnou k důkladné analýze. Pozorováním skvrn můžeme lépe porozumět Slunci a přesněji predikovat případné ohrožující výrony hmoty.

Sluneční skvrny vznikají kvůli magnetickému poli Slunce, které se vlivem diferenciální rotace v průběhu 11letého slunečního cyklu mění a zamotává. Poloha slunečních skvrn se během tohoto cyklu mění. Na začátku cyklu, tedy v době minima, se skvrny vyskytují v oblastech kolem $+30^\circ$ a -30° heliografické šířky a postupem cyklu se skvrny dostávají blíže k rovníku. Skvrny se jen velmi vzácně dostanou nad $+45^\circ$ nebo pod -45° heliografické šířky. Tato oblast nejpravděpodobnějšího výskytu se nazývá královský pás. Postupný posun oblastí výskytu skvrn k rovníku v průběhu cyklu se vynáší do tzv. motýlkového diagramu, viz. Obrázek 3. Z grafu je taktéž patrné rozdělení jednotlivých cyklů. Mnohdy se ale cykly na svém konci a začátku překrývají. Na disku se pak mohou vyskytovat skvrny ze dvou cyklů zároveň. [9]



Obrázek 3: Motýlkový diagram [10]

je přisuzován jemu, skvrny před ním pozoroval dalekohledem i Galileo Galilei nebo Thomas Harriot. Skvrny je možné pozorovat i pouhým okem. Aby bylo možné skvrny takto spatřit, musí být Slunce bud' kryto vrstvou průsvitných mraků nebo širší vrstvou atmosféry. To nastává při východu nebo západu Slunce, kdy je sluneční disk u obzoru a světlo průchodem atmosféry více slabne. Takto byly skvrny spatřeny už před tisíci lety.

3.1 Schwabeův sluneční cyklus

Jak již bylo zmíněno, Slunce má periodicitu ve své aktivitě. Tato perioda je cca 11 let, ale může se pohybovat i mezi 9 a 15 lety, a je známa jako Schwabeův sluneční cyklus, Schwabe-Wolfův cyklus, cyklus slunečních skvrn, případně anglicky *solar cycle*. [12] Tento cyklus objevil a



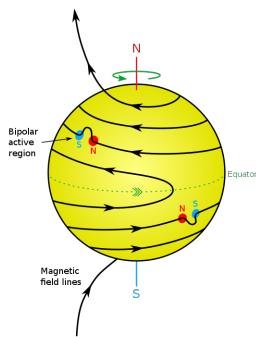
Obrázek 2: Sluneční skvrny na slunečním disku [8]

Jak již bylo zmíněno, sluneční skvrny jsou systematicky pozorovány přes čtyři staletí. Za tu dobu došlo k výrazné změně v jejich pozorování. I přestože prvně popsal skvrny Johannes Fabricius roku 1611 [11], a tedy objev skvrn

popsal německý lékárník a amatérský astronom Heinrich Schwabe roku 1843 na základě napozorovaných dat.

Cyklus úzce souvisí s magnetickým polem Slunce, tedy i s tvorbou a polohou slunečních skvrn. V cyklu hraje velkou roli diferenciální rotace Slunce. Jedná se o rozdílnou rotaci na slunečním rovníku a v blízkosti slunečních pólů. Zatímco se sluneční rovník otočí jednou za 25,4 dne,

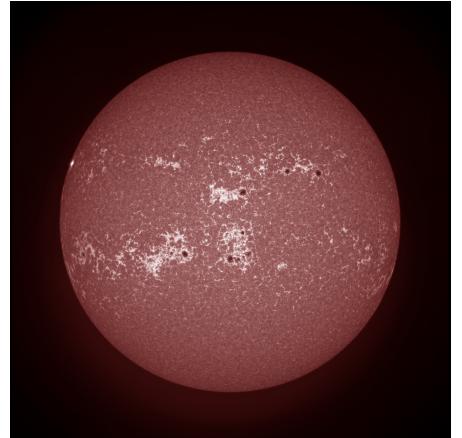
okolí slunečního pólu to trvá o 10,6 dne déle. Vlivem této rotace dochází právě k zauzlovávání magnetického pole a k tvorbě skvrn, viz Obrázek 3Obrázek 4. Na začátku svého cyklu má Slunce své dva magnetické póly na severním a jižním pólu, tedy tam, kde bychom je čekali, a magnetické indukční čáry vedou přímo mezi oběma póly. Důsledkem diferenciální rotace dochází k různě rychlému pohybu každé magnetické indukční čáry na rovníku a na pólu a magnetické pole se stává komplikovanějším. Takto se magnetické indukční čáry pořád zhuštějí. Pokud se stane, že magnetické pole je už moc komplikované, dojde k přepojování jednotlivých čar a k výskytu lokálních pólů v místech tohoto přepolovování. Celý cyklus je nakonec dovršen přepolovováním celého Slunce a opět se celý systém zjednoduší, tentokrát s opačnou polohou magnetického severního a jižního pólu. Toto nastává přibližně po 11 letech, ale lze se také dočít o 22letém cyklu. Touto dobou se myslí čas, za který se magnetické póly opět vrátí na polokoule, kde začínaly.



Obrázek 4: Znázornění diferenciální rotace, na disku jsou patrné dvě skupiny skvrn [13]

3.2 Tvorba slunečních skvrn

Sluneční skvrna je místo, kde na povrch vystupují magnetické indukční čáry, které bývají normálně pod povrchem, ale vlivem namotání došlo k jejich zauzlování či případnému přepojení. Tyto změny pak pozorujeme ve fotosféře a nazýváme je slunečními skvrnami nebo skupinami slunečních skvrn. Místo, kde siločáry vystupují na povrch, se nám jeví jako černé, i přestože má teplotu kolem 4000 K. Toto místo nazýváme umbra, česky stín. Kolem umbry je také možné spatřit penumbru, polostín, což je jakýsi přechod mezi klasicky granulovaným slunečním povrchem a umbrou. Penumbra je světlejší než umbra, neboť i zde magnetické siločáry zabírají dostatečnému energetickému přesunu z konvektivní vrstvy, ale pouze částečně. Před vznikem a po zániku sluneční skvrny se obvykle na stejném místě vyskytují fakulová pole, která jsou složené z jednotlivých fakulí, viz Obrázek 5. Fakule se vyskytují stejně jako skvrny ve fotosféře a jedná se o body, které jsou jasnější než sluneční disk, neboť mají teplotu přibližně o 300 K vyšší než okolí. Fakulová pole stejně jako sluneční skvrny značí jistou poruchu magnetického pole, ale na rozdíl od skvrn magnetické pole ve fakulových polích zůstává pod povrchem Slunce.



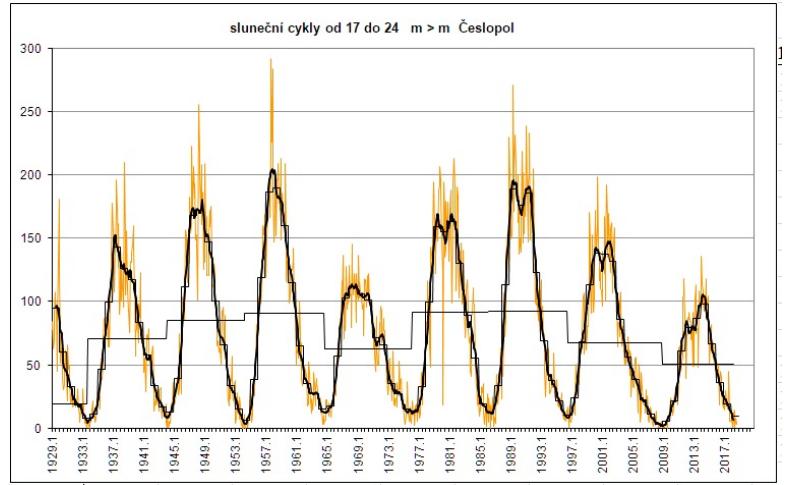
Obrázek 5: Znatelná světlá fakulová pole a tmavé sluneční skvrny ze srpna 2014 [14]

3.3 Skupiny skvrn

Paradoxně skupinou skvrn může být i pouze jedna skvrna, neboť hlavním znakem skvrny je, že se jedná o jeden uzavřený systém s póly. Můžeme mít tedy velmi komplikovaný systém několika desítek skvrn a bude se jednat o jednu skupinu skvrn, stejně tak jako můžeme mít pouze jednu skvrnu a bude se také jednat jen o jednu skupinu. Skvrny ve skupině mohou zanikat a přibývat, ale většinou jsou patrné dvě větší skvrny, které mají svůj specifický název na základě své polohy. Skvrna na západě se nazývá vedoucí, skvrna na východě chvostová. [15] Tyto skvrny většinou přetrvají celou dobu výskytu skupiny. Velikost skupiny, počet skvrn a další parametry skupiny mají vliv na životnost skupiny. Nejčastěji skupiny vydrží několik dní, menší jen několik hodin a větší mohou až několik týdnů.

3.3.1 Polarita skupin

Skupina skvrn se označuje vždy buď jako unipolární nebo bipolární. Bipolární skupina je ta skupina, která má více než dvě skvrny, a magnetické pole v minimálně jedné z nich vystupuje a v dalších skvrnách nebo skvrně opět vstupuje do Slunce. U těchto skupin lze poté například pomocí magnetografu určit záporný a kladný pól skupiny. Skvrna vedoucí a



Obrázek 6: Graf relativního čísla mezi lety 1929 a 2017 sesbírané skupinou Česlopol [16]

chvostová mají vždy opačnou polaritu. Naopak u unipolárních skupin magnetické indukční čáry ze skvrny pouze vystupují a do žádného konkrétního pólu nevstupují. Ve skutečnosti se ale rovnoměrně napojí na celý sluneční disk. Unipolární skupiny by tedy měly mít pouze jednu skvrnu, neboť při více skvrnách se ze systému stane bipolární systém.

3.3.2 Relativní číslo

S velikostí a počtem skvrn ve skupinách velmi úzce souvisí relativní číslo, což je index, který se používá k určení celkové aktivity Slunce. Tento index zavedl astronom Rudolf Wolf někdy v 19. století. [17] Výpočet tohoto indexu je velmi jednoduchý, relativní číslo R dostaneme jakožto součet desetinásobku počtu skupin skvrn na slunečním disku a jednotlivých skupin ve skvrnách. Tento index, někdy zvaný Wolfovo číslo, má většinou hodnotu mezi 0 a 300, viz Obrázek 6. [18] Díky tomu, že tento index je zaznamenávám už přes dvě století, je vhodný ke zpracování pozorování celkové aktivity Slunce. I přesto tento index není perfektní a existují i jiné indexy k popsání sluneční aktivity.

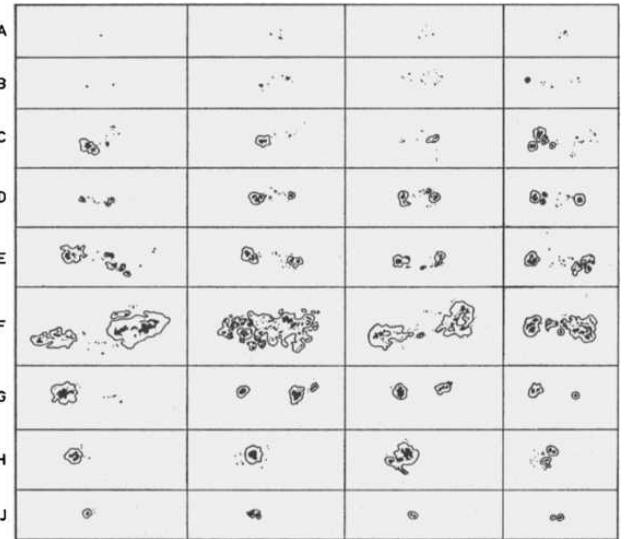
3.4 Klasifikace aktivní oblasti

Skupiny skvrn, také nazývány aktivními oblastmi, se navzájem dokáží velmi odlišovat, a proto bylo nutné zavést nějaký systém. Nyní existuje mnoho těchto klasifikací, které zohledňují například velikost skupiny, polaritu skupiny, rozložení skupiny atp. Hlavní motivací ve vytváření nových klasifikací je zlepšení predikce tvorby erupcí na základě struktury skvrny. V tuto chvíli zatím neexistuje vyhovující metoda k přesnému predikování tvorby erupcí, jedná se o velmi komplikovaný úkol.

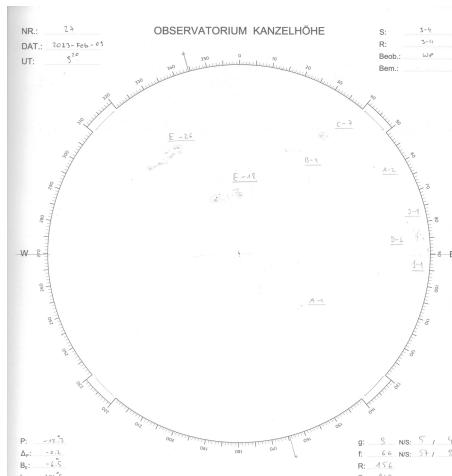
3.4.1 Curyšská klasifikace

Jedna z prvních a dodnes používaných klasifikací je Curyšská klasifikace, která byla zavedena v roce 1938 M. Wiedermaierem.

Klasifikace má celkem devět tříd: A, B, C, D, E, F, G, H, J, viz Obrázek 7, a každá tato skupina má svou definici. [19] Skupina třídy A sestává z jedné nebo více skvrn bez penumbry a bez bipolární konfigurace. Třídu B označíme skupinu bez penumbry s bipolární konfigurací. Třída C je bipolární skupina skvrna s jednou skvrnou, která má penumbru. Pokud se jedná o skupinu, jejíž největší skvrna má penumbru a celá skupina nepřesahuje velikost přes více než 10° (míněno v heliografických souřadnicích na povrchu Slunce), dostane skupina označení D. Jestliže je skvrna větší, konkrétně mezi 10° a 15° , bude se jednat o typ E. Ještě větší skupinu pak označíme písmenem F. Bipolární skupinu obsahující penumbry a žádné malé skvrny mezi hlavními skvrnami a délku nad 10° klasifikujeme jako třídu G. Třídy H i J se také odlišují pouze velikostí skupiny, pokud se bude jednat o jednu skvrnu s penumbrou a velikostí větší než $2,5^\circ$, dostane skupina, ve které je pouze jedna skvrna, označení H. Pokud je skvrna menší než $2,5^\circ$, jedná se o typ J. Uspořádání tříd za sebou má reflektovat vývoj skupiny, který začíná na třídě A a končí u třídy J, avšak ne všechny skupiny slunečních skvrn projdou všemi třídami.



Obrázek 7: Příklady jednotlivých tříd Curyšské klasifikace [20]



Obrázek 8: Zákre z Observatoře Kanzelhöhe

Pro možnost lepšího analytického zkoumání se jednotlivým kategoriím přidává váhové číslo a po součtu všech těchto čísel jednotlivých skvrn dostaneme Beckovo číslo slunečních skvrn. Jednotlivé váhy kategorií jsou: A = 4; B = 4; C = 8; D = 18; E = 25; F = 36; G = 50; H = 44; J = 37. Beckovo číslo slunečních skvrn vypočteme následujícím vztahem:

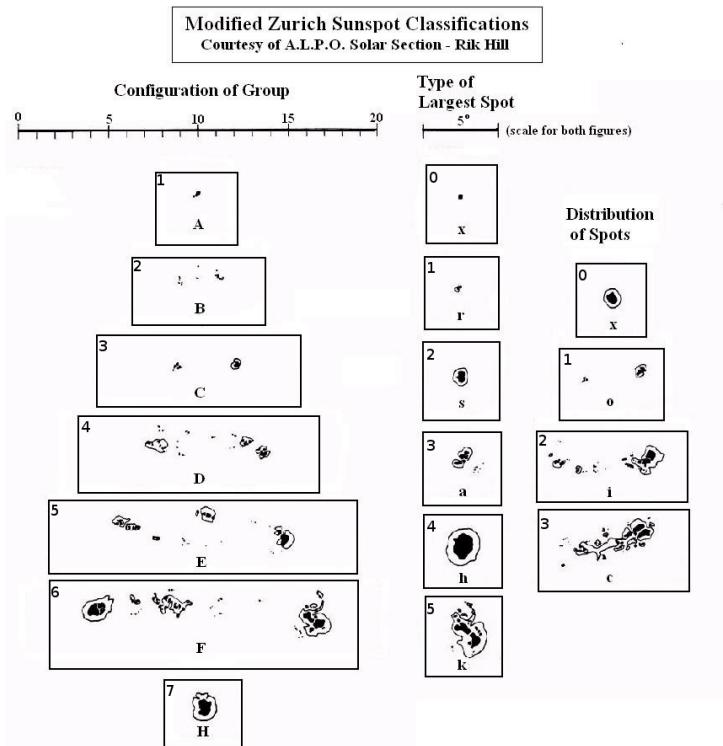
$$R_B = \sum w_i \cdot f_i, \quad (1)$$

kde w_i jsou váhové čísla a f_i počet skvrn v jednotlivých skupinách. [21] Klasifikace se bohužel neosvědčila při predikci slunečních erupcí a byla potřeba ji pozměnit. Tak vznikla navazující McIntoshova klasifikace. I přesto se nadále tato klasifikace pořád používá, například v Observatoři Kanzelhöhe v jižním Rakousku, viz Obrázek 8: Zákres z Observatoře Kanzelhöhe, hlavně kvůli dodržení historické řady.

3.4.2 McIntoshova klasifikace

McIntoshova klasifikace, která byla vymyšlena roku 1966, se skládá z tří různých takřka nezávislých klasifikací, které dohromady určují třípísmenné označení skupiny, viz Obrázek 9. Skvrny tedy mohou mít označení například Axx, Dai či Eso.

Prvními písmeny jsou A, B, C, D, E, F, H a jejich definice je velmi podobná té předešlé z Curyšské klasifikace. Někdy se tato podklasifikace nazývá modifikovaná curyšská klasifikace právě podle návaznosti. Třída A je unipolární skupina bez penumber. Třída B je bipolární skupina bez penumber. Třídou C pak bude označena ta bipolární skupina, která obsahuje penumbru na jednom ze svých okrajů. Pokud skupina obsahuje více penumber, bude se jednat o jednu ze tří tříd – D, E nebo F. Zde opět záleží na velikosti skvrny, pod 10° se jedná o typ D, mezi 10° a 15° sahají skupiny E a větší se pak označují písmenem F. Pokud se jedná o unipolární systém s penumbrou, označíme ho písmenem H. [23]



Obrázek 9: Souhrnný obrázek k McIntoshově klasifikaci [22]

Axx = 1					
Bxo = 2 Bxi = 3					
Hrx = 4 Hax = 7 Hsx = 10 Hkx = 37 Hhx = 40	Hrx = 4	Cro = 5 Cri = 6	Dro = 13 Dri = 16	Ero = 14 Eri = 17	Fro = 15 Fri = 18
	Hax = 7	Cao = 8 Cai = 9	Dao = 19 Dai = 22	Eao = 20 Eai = 23	Fao = 21 Fai = 24
	Hsx = 10	Cso = 11 Csi = 12	Dso = 25 Dsi = 28 Dac = 31 Dsc = 34	Eso = 26 Esi = 29 Eac = 32 Esc = 35	Fso = 27 Fsi = 30 Fac = 33 Fsc = 36
	Hkx = 37	Cko = 38 Cki = 39	Dko = 43 Dki = 46	Eko = 44 Eki = 47	Fko = 45 Fki = 48
	Hhx = 40	Cho = 41 Chi = 42	Dho = 49 Dhi = 52 Dkc = 55 Dhc = 58	Eho = 50 Ehi = 53 Ekc = 56 Ehc = 59	Fho = 51 Fhi = 54 Fkc = 57 Fhc = 60

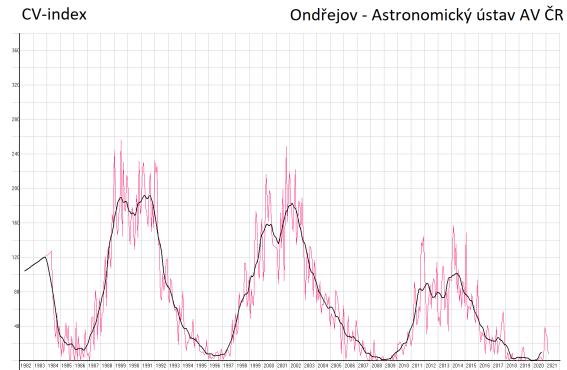
Obrázek 10: Tabulka s hodnotami CV indexu všech typů McIntoshovy klasifikace [24]

částech nemá jasné hranice. Typ h je poté ekvivalentem pro typ s, se změnou velikosti skvrny, a to nad $2,5^\circ$. Typ k je stejnou logikou ekvivalentní k typu a, tedy asymetrická penumbra přesahující $2,5^\circ$. [25]

Třetí symbol pak charakterizuje rozložení skvrn ve skupině. K označení 4 tříd se používají písmena x, i, o, c. Typ x je unipolární skupina, tedy pokud skupinu označíme jako A nebo H, automaticky dostane písmeno x. Třídou o, z anglicky *open*, otevřené, označíme tu skupinu, ve které jsou skvrny buď u jednoho nebo u druhého pólu skvrny a nikoliv mezi. Třída i, z anglicky *intermediate*, přechodné, je vyhrazena pro konfiguraci, kde skvrny leží i mezi póly skupiny. Pokud by ale takto mezi vedoucí a chvostovou skvrnou byla skvrna s penumbrou, jednalo by se o třídu c, z anglicky *compact*, kompaktní.

Jak již bylo řečeno, ne všechny kombinace písmen lze nalézt, neboť některá jsou vázány na výskyt penumbry a jiná naopak na absenci její přítomnosti. Proto se na slunečním disku může vyskytnout pouze 60 tříd a každá tato třída má hodnotu od 1 do 60, která se používá k výpočtu klasifikační hodnoty, spíše známé pod názvem index CV nebo classification value. Jedná se o obměnu Beckova indexu z Curyšské klasifikace. CV index opět slouží k převedení klasifikace na číslo. Jednotlivé hodnoty, včetně všech možných kombinací písmen zobrazuje Obrázek 10. Tato hodnota opět může sloužit k charakterizaci sluneční aktivity, viz Obrázek 11.

Druhé písmeno klasifikace poté charakterizuje největší skvrnu ve skupině. Na výběr máme z 6 tříd označených x, r, s, a, h, k. Typ x může nastat pouze v kombinaci s třídami A nebo B, jelikož toto označení použijeme, pokud největší skvrna nemá penumburu. Třída r, z anglicky *rudimentary*, základní, označuje situaci, pokud je penumbra nerozvinutá, neúplná a nepravidelná. Typ s, z anglicky *symmetric*, symetrická, značí penumburu symetrickou a menší než $2,5^\circ$. Typ a, z anglicky *asymmetric*, nesymetrická, se použije, pokud penumbra nepřesahuje $2,5^\circ$ a zároveň není symetrická a například v určitých



Obrázek 11: Nasbírané hodnoty CV indexu Astronomickým ústavem AV ČR [26]

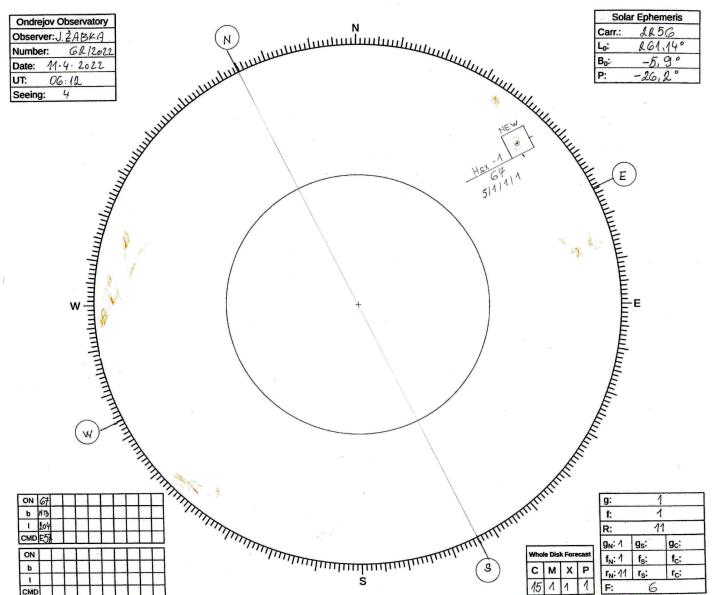
3.4.3 Mount Wilson klasifikace

Další klasifikace vznikla na základě napozorovaných dat magnetogramů mezi lety 1959 a 1962 na Observatoři Mount Wilson. Tato klasifikace má 4 hlavní třídy, které se ale mezi sebou mohou různě kombinovat. Třídy jsou označeny α , β , γ , δ , $\beta\text{-}\gamma$, $\beta\text{-}\delta$, $\beta\text{-}\gamma\text{-}\delta$, $\gamma\text{-}\delta$. α je označení pro unipolární skupinu. Třída β označuje skupinu slunečních skvrn, kde lze zřetelně rozeznat skvrny z opačnými polaritami. Třídou γ označíme tu skupinu, která už má komplikovanější polaritu. Označení δ je velmi specifické. Používá se v případě, že v penumbře jedné skvrny se vyskytuje jak kladná, tak záporná polarita. Kombinace $\beta\text{-}\gamma$ poté označuje skupinu, která má patrné hlavní skvrny opačné polarity, ale nelze přesně určit hranici mezi kladným a záporným polem skupiny. Třída $\beta\text{-}\delta$ je označení pro skupinu, která má magnetické pole jako β třída, ale vyskytuje se zde alespoň jedna δ skvrna (skvrna s penumbrou dvojí polarity). Třída $\beta\text{-}\gamma\text{-}\delta$ má rozložení jako třída $\beta\text{-}\gamma$ ale opět se zde objevuje jedna či více δ skvrn. Klasifikace $\gamma\text{-}\delta$ je poté opět kombinace třídy γ s nejméně jednou δ skvrnou.

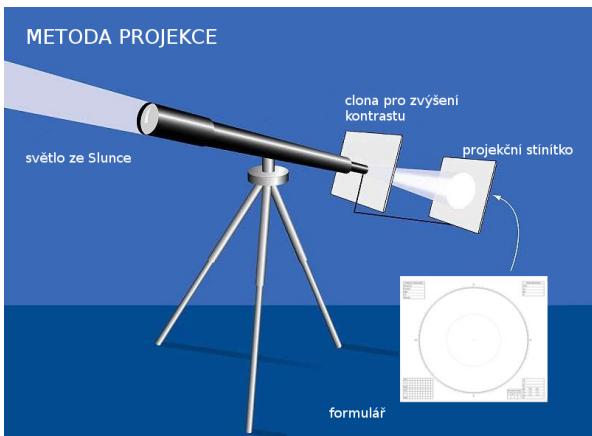
3.5 Kresba Slunce

Kresba Slunce je metoda zachycení detailů na Slunci, kterou začal používat již Galileo Galilei. Příklad kresby zobrazuje Obrázek 12. Při této metodě se dalekohled používá jako promítací aparát a Slunce promítá na papír, kde jsou poté skvrny i další úkazy ručně zakresleny. I přestože je s moderními technologiemi možné získat daleko kvalitnější informace, je stále tato metoda nejjednodušší (nejenom) pro amatérské astronomy.

Zároveň se také jedná o metodu pozorování Slunce, kterou je pozorováno nejdéle, a kombinací nových družicových dat a nových kreseb dokážeme lépe zpřesnit, co se dělo v době, kdy se Slunce pouze kreslilo. Slunce se standardně kreslí do protokolů s velikostí slunečního disku 25 cm, nikdy by nemělo být kresleno do kotouče menšího než 10 cm. Jelikož je Slunce úhlově velký objekt, lze ke kresbě použít dalekohled s průměrem objektivu 5 cm nebo větším a ohniskovou vzdáleností 80 cm. Tento dalekohled by měl mít paralaktickou montáž s pohonem. Nejen že tato montáž sama sleduje Slunce, ale také s ní lze jednoduše zorientovat protokol simulováním denního pohybu, tedy pohybem v rektascenzi. [25]



Obrázek 12: Názorná ukázka kresby z Ondřejovské hvězdárny [27]



Obrázek 13: Názorná ukázka využití dalekohledu k promítání Slunce na protokol [28]

společně s Astronomickým ústavem AV ČR a Solární patrolou sídlící v Ondřejově, sepsala manuál, jak kreslit. Postup zakreslování je následující:

1. Dalekohled bezpečně namíříme na Slunce a na stínítko položíme formulář, viz Obrázek 13.
2. Vypneme hodinový stroj, případně simulujeme denní pohyb Slunce a tím zorientujeme kresbu.
3. Zpřesníme zorientování formuláře přesunem skvrny na spojnici východu a západu a natočíme protokol tak, aby se skvrna při pohybu v rektascensi hýbala pouze po spojnici.
4. Opět zapneme hodinový stroj a umístíme Slunce přesně na formulář.
5. Zakreslíme úkazy na Slunci. Umbry plně černé, penumbry šedé, případně pouze obrysy a filamenty žlutou nebo červenou pastelkou.
6. Zkontrolujeme správnost zákresu
7. Doplníme informace do tabulek ve formuláři.

3.5.2 Informace v protokolu

V protokolu nesmí chybět různé informace, a to datum a čas vyhotovení kresby, místo pozorování a jméno pozorovatele, viditelnost (seeing) na škále od 1 do 5, kde 5 je nejlepší, číslo kresby, obvykle ve formátu číslo kresby v roce/daný rok. Dále také údaje o slunečním disku – heliografická šířka a délka centra slunečního disku a úhel, o který je natočena rotační osa Slunce a číslo Carringtonovy rotace, což značí pořadí otočky Slunce kolem své osy od 9. listopadu 1853. [30] Dále by měly být zakreslené skupiny skvrn ohraničené obdélníkem a očíslované, případně i oklasifikované. V protokolu by také měly být informace o aktivitě Slunce. Mezi tyto informace řadíme počet skvrn na disku, počet skupin na disku a Wolfovo číslo. Dále je také možné skupiny skvrn rozložit do tří sektorů, centrální, severní a jižní a tyto údaje vypočítat pouze pro daný sektor. V neposlední řadě by také na kresbě měl být uveden počet fakulových

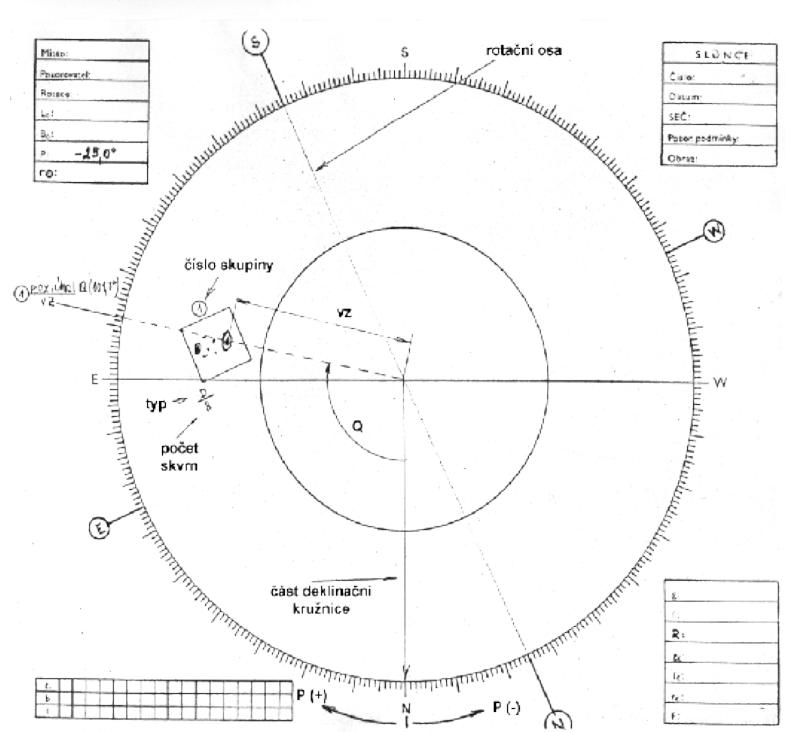
polí. Do protokolu se také zapisují informace o poloze každé skupiny. Jedná se o heliografickou šířku a heliografickou délku středu skupiny, případně i jejich polohu vůči středu kresby. Heliografické souřadnice skupiny lze vypočítat pomocí těchto vzorců [25]:

$$\rho = \sin^{-1} \frac{vz}{R} \quad (2)$$

$$b = \sin^{-1} (\sin B_0 \cos \rho + \cos B_0 \sin \rho \cos(P - Q)) \quad (3)$$

$$l = \left(\sin^{-1} \frac{\sin \rho \sin(P-Q)}{\cos b} \right) + L_0, \quad (4)$$

kde vz je vzdálenost středu skvrny od středu kresby, R je velikost slunečního disku na kresbě, B_0 je heliografická šířka středu kresby, L_0 je heliografická délka středu kresby, P je poziciční úhel rotační osy Slunce a Q je poziciční úhel skupiny měřený na kresbě od severu přes východ. b a l jsou pak hledanými heliografickými souřadnicemi, šířkou a délkom, skupiny. Znázornění získání potřebných údajů o skupině ukazuje Obrázek 14.



Obrázek 14: Výskyt údajů na kresbě [31]

4 STROJOVÉ UČENÍ

Strojové učení může být chápáno jako souhrnné označení metod, nelineárních algoritmů, které mají za cíl splnění určitého úkolu. Tímto cílem pak může být v podstatě cokoliv. Ať už rozřazování do kategorií, predikování číselné hodnoty na základě předešlého vývoje, nalezení podobných dat na vstupu nebo vygenerování obsahu. Kategorizace objektů může být využita v chytrých autech na zmapování okolí pomocí kamery, příkladem predikce je model snažící se odhadnout ceny akcií a velké jazykové modely generující obsah se těší velké popularitě, příkladem může být ChatGPT [32], model generující text, nebo DALL-E [33], sloužící ke generaci obrázků.

Pro každou úlohu se hodí individuální přístup tvorby. [34] Ten může být rozdělen do tří následujících kategorií.

1. učení s učitelem (angl. *supervised learning*)
2. učení bez učitele (angl. *unsupervised learning*)
 - a. *semi-supervised learning*
 - b. vlastní učení (angl. *self-supervised learning*)
3. zpětnovazebné učení³ (angl. *reinforcement learning*)

Princip učení s učitelem je velmi jednoduchý, ke vstupním datům jsou přiřazeny správné výstupní údaje a program se snaží zobecnit své chování tak, aby dokázal využít poznatky z trénovacích dat na testovacích datech. Například se může jednat o obrázky auta a psa, rozřazené podle toho, co se na obrázku nachází. Model poté přesně ví, který vstup označil správně a který špatně, a může se díky této informaci zlepšovat.

Do další kategorie lze zařadit více metod. Jejich hlavním spojovacím znakem je, že nemají na rozdíl od učení s učitelem.

V případě učení bez učitele dostane model za úkol sám poznat, jaká vstupní data k sobě patří, například tím, že zvolením vhodných operací se stejná data začnou navzájem shlukovat. Příkladem mohou být fotografie noční oblohy a květin, kde musí program sám pochopit, že pokud je fotka tmavá, jedná se o noční oblohu, a naopak. Do této kategorie lze také přiřadit další metody, jejichž hlavním znakem je, že taktéž nemají k dispozici vstupní data s přiřazenými správnými výstupy. Jeden z těchto způsobů učení je *semi-supervised learning*. Jedná se o kombinaci učení s a bez učitele. Dále sem spadá i *self-supervised learning*. Algoritmy používající tento způsob nepotřebují mít vůbec ke vstupním datům označené jejich správné výstupní hodnoty. Touto metodou například vznikají velké jazykové modely, například

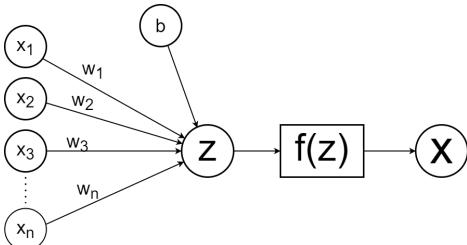
³ Jedná se ovšem o nepřesný překlad, neboť zpětná vazba se vyskytuje i při učení s učitelem.

Gemini [35], které mohou sloužit například vést dialog s uživatelem. Tyto modely jsou trénovány na rozsáhlých textech a náhodně si v nich maskují, mažou, slova a snaží se správně uhodnout na základě jiného textu takto zamaskovaná slova. Jelikož model zná slovo, které se ve vstupním textu vyskytuje a ví, které slovo by doplnil, tak má k dispozici informaci o správnosti svého doplnění a tu může využít ke zlepšení.

Zpětnovazebné učení se učí na základě pozitivní nebo negativní reakce na dané akce, případně změny, avšak v jiné podobě, než je tomu při učení s učitelem.

4.1 Neuronové sítě

Neuronová síť je dnes již zcela dominantní algoritmus, metoda strojového učení, díky kterému lze natrénovat chování modelu. Základním znakem neuronových sítí je, že obsahují neurony. První umělý neuron byl vytvořen již v polovině 20. století. Ty jsou inspirovány neuronovými buňkami v mozku. Neurony tvořící neuronové sítě jsou na sebe vzájemně napojeny, viz Obrázek 15, a stejně jako mozkové neurony mohou být aktivovány. Neurony svou míru aktivace, svou hodnotu, získávají na základě hodnoty předchozích neuronů pomocí jednoduchých matematických operací.

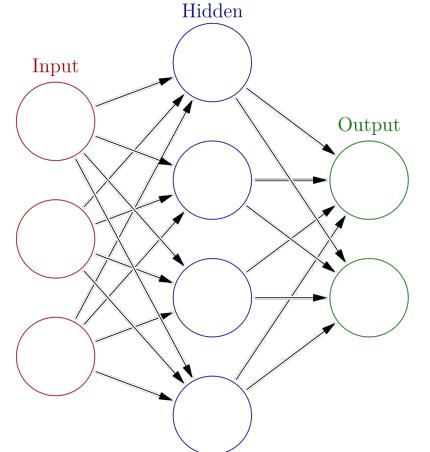


Obrázek 16: Proces výpočtu hodnoty neuronu

Výpočet hodnoty neuronu je velmi jednoduchý a díky tomu je možné vytvářet rozměrné vrstvy se spoustou neuronů a napojení. Každý neuron ve vyšší vrstvě je napojen na všechny neurony z předešlé vrstvy a má k dispozici všechny předešlé hodnoty neuronů. Mezi neuronem ve vyšší a nižší vrstvě tedy existuje spojení a toto spojení má vždy určitou váhu. Tu lze chápat jako důležitost spojení, ale především se jedná o jeden z trénovatelných parametrů neuronové sítě. Mezi hodnotu neuronu, označovanou z , se vypočítá de facto lineárními rovnicemi. Jedná se o součet sumy všech vážených hodnot předešlých neuronů a hodnoty *bias*, česky práh, charakteristické pro každý neuron a neovlivněné vstupními daty, tedy:

$$z = \sum_{i=1}^n (x_i w_i) + b, \quad (5)$$

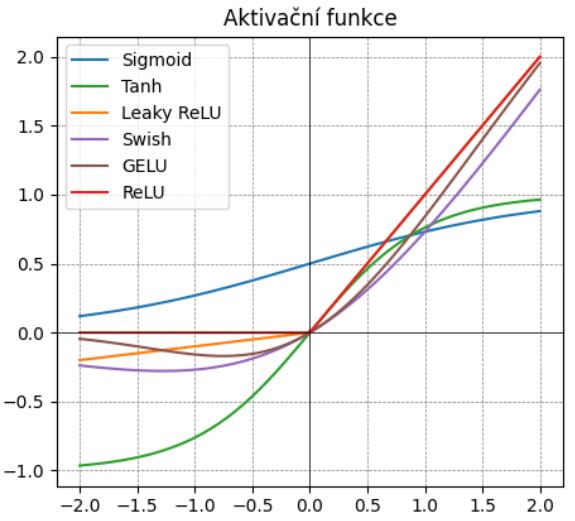
kde x_i je hodnota předešlého neuronu, w_i je váha spojení obou neuronů a b je bias. Celý proces znázorňuje Obrázek 16. Na tomto obrázku lze vidět, že po výše zmínovaném součtu je na hodnotu z aplikována funkce $f(z)$. Použití funkce má za cíl vnést nelinearitu do celého procesu. Tím se značně zlepšují možnosti trénovaní modelů. Tato funkce se nazývá aktivační funkce. [37] Přehled těch nejzákladnějších ukazuje Obrázek 17. Výsledná hodnota neuronu x pak může být vzorcem formulována jako:



Obrázek 15: Struktura vrstev neuronové sítě [36]

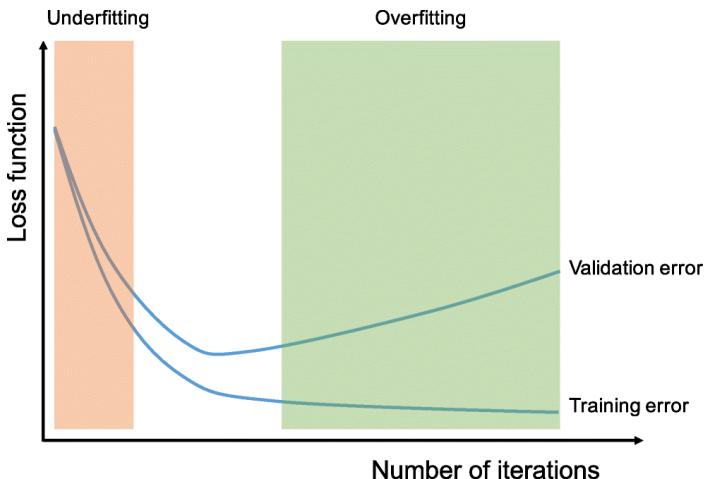
$$x = f(z) = f(\sum_{i=1}^n (x_i w_i) + b). \quad (6)$$

Jak už předchozí text naznačuje, neurony jsou v neuronových sítích uspořádány do vrstev. První vrstva neuronů se nazývá vstupní vrstva. Tato vrstva pouze přebírá data ze vstupních dat a případně je upravuje. Poté následuje několik skrytých vrstev. Každá tato skrytá vrstva může mít jiný počet neuronů. Tento počet se může postupně snižovat nebo zvyšovat. Pro každou úlohu je vhodné jiné nastavení. Pro tyto vrstvy je charakteristické napojení každého neuronu ve vyšší vrstvě na všechny neurony z předešlé vrstvy. Poslední vrstva neuronové sítě je výstupní vrstva. V případě klasifikačních úloh do různých skupin má přesně tolik neuronů, jako je výstupních tříd. Hodnoty těchto posledních neuronů pak udávají pravděpodobnosti zařazení vstupu do jednotlivých tříd.



Obrázek 17: Ukázka některých aktivačních funkcí

Průchod vstupních dat přes vrstvy je označován jako dopředná propagace, angl. *forward propagation*. Proces učení pak probíhá opačným směrem a je označován jako zpětná propagace, angl. *backpropagation*. [38] Tento proces byl popsán roku 1970. K pochopení konceptu zpětné propagace je nutné zmínit ještě chybovou funkci [39], angl. *loss function* či *cost function*. Tato funkce reprezentuje celkovou úspěšnost modelu. Čím nižší její hodnota je, tím lépe by měl model umět rozhodovat mezi třídami. Cílem trénování je tedy dosáhnout nejnižší hodnoty loss funkce, neboť to by mělo odpovídat stavu, kdy je model nejobecnější. Výsledná funkce závisí kromě vstupních dat také na všech váhách a biasech modelu. Matematickými operacemi lze zjistit, jak moc které hodnoty ovlivňují podobu výsledné funkce, a na základě toho mohou být tyto parametry pozměněny tak, aby byla predikce úspěšnější. Většinou není snížení nebo zvýšení parametru provedeno v plném rozsahu, ale veškeré změny se vynásobí parametrem *learning rate*, který je menší než jedna, a který způsobuje pomalejší změnu parametrů, a tedy hladší průběh trénování. Po změně parametrů bývají modelu dána nová vstupní data a celý proces běží znova. Tímto lze docílit generalizace modelu pro velké množství vstupních dat. Při trénování velkých modelů je běžné, že se proces zpětné propagace provádí až po analýze více



Obrázek 18: Ukázka *overfittingu* na chování loss funkce [40]

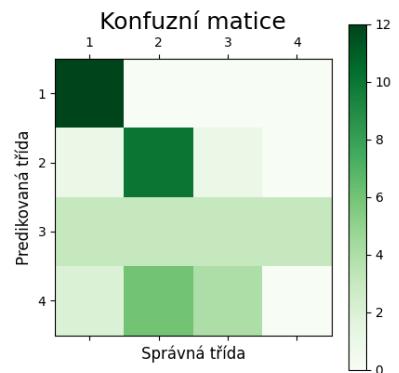
vstupních dat a nikoliv jednoho. Počet dat, které takto model například klasifikuje během jednoho kroku, se nazývá *batch size*.

Při neustálém učení modelu na těch samých vstupních datech může dojít k přetrénování modelu, anglicky označované *overfitting*. Model poté sice vykazuje větší přesnosti na trénovacích datech, ale na nových datech by se mu přesnost snižovala.

Model si totiž de facto zapamatovává

obrázky, které viděl a snaží se chování uzpůsobit přímo jím, a nikoliv se zobecňuje. I přestože *overfitting* nelze pozorovat na přesnosti modelu při trénování, lze jej odhalit z hodnoty loss funkce. Její hodnota se totiž při přetrénování opět zvedá, to zobrazuje Obrázek 18.

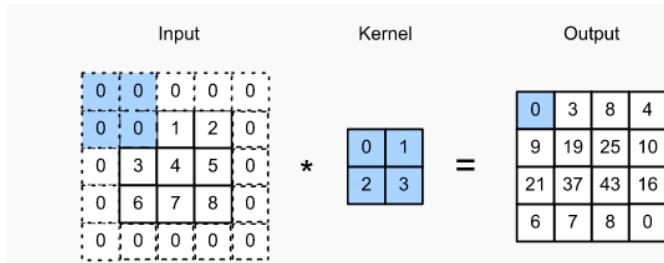
Trénování probíhá na vstupních datech, které se ještě před začátkem rozdělí do tří množin, trénovací, validační a testovací. [41] Taktéž se používá označení trénovací, validační, nebo testovací dataset. Model se učí z velké části jen na trénovacích datech, a proto by tato množina měla obsahovat nejvíce vzorků. Po každé epoše, angl. *epoch*, přijde na řadu druhá množina, validační, která slouží jako referenční data, na kterých může model zkoumat svou přesnost a přetrénování. Testovací množina pak slouží k vyhodnocení přesnosti modelu. V této množině by měli být pouze vstupní data, která model neměl při trénování k dispozici, neboť v opačném případě by výsledek testování nereprezentoval chování modelu na náhodných datech. V případě klasifikačních modelů lze výsledek interpretovat i takzvanou maticí záměn, konfuzní maticí, angl. *confusion matrix*. [42] Její slouče nesou informaci o správném zařazení výstupu, řádky nesou informaci o zařazení modelem. Pohledem na Obrázek 19 lze tedy vyčist, že model predikoval rozřazení do čtyř tříd, první třídu naprostě bezchybně predikoval, druhou predikoval pouze s malými chybami, vzorky třetí třídy označil stejněkrát jako vzorky všech tříd a čtvrtou třídu nikdy správně nepredikoval, zaměňoval ji nejvíce s druhou třídou.



Obrázek 19: Příklad konfuzní matici

4.1.1 Konvoluční neuronové sítě

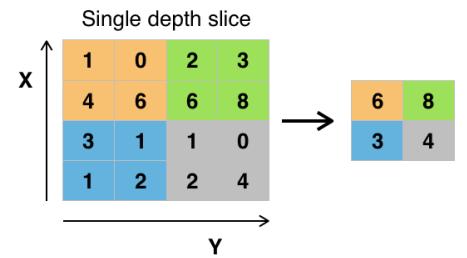
Konvoluční neuronová síť, angl. *convolutional neural network*, zkr. CNN, je specifický typ neuronové sítě, který se osvědčil na práci s obrázky. Na rozdíl od základní verze dopředné neuronové sítě mají v sobě neurony zabudovanou informaci o poloze vstupních dat, pixelů na obrázku a mohou tedy lépe chápát návaznost různých prvků ve vstupních datech. Také jsou některé váhy spojení mezi neurony stejné, čímž se značně zmenšuje počet parametrů, a to značně urychlují síť a dává prostor pro tvorbu komplexnějších struktur.



Obrázek 21: Výpočet hodnot neuronů v konvoluční síti [43]

sítí a neurony v této vrstvě jsou napojeny na všechny neurony předchozí vrstvy. CNN dostala název konvoluční díky charakteristickým konvolučním vrstvám. Ty fungují tak, že hodnota neuronu vyšší vrstvy je počítána pouze z určité oblasti předchozí vrstvy⁴. Hodnoty vah spojení se pak většinou uspořádávají do matic, nejčastěji velikosti 3×3 , které odborně nazýváme filtrem, anglicky také *kernel*. Výpočet hodnot neuronů zobrazuje Obrázek 21. Dalšími speciálními vrstvami CNN jsou *pooling* vrstvy, které snižují dimenzi výstupu předešlé vrstvy. Příkladem může být maxpooling vrstva, která ze zadané oblasti vezme pouze nejvyšší hodnotu neuronu. Vznikne tedy vrstva s menší velikostí, přímo úměrnou oblasti, ve které probíhá vybírání nejvyšší hodnoty, viz Obrázek 20. [45] Další operací, která také může být chápána jako vrstva je vyrovnání dat za sebe, angl. *flatten*. [46] Zarovnáním dat do řady dojde sice ke ztrátě informace o poloze pixelu, ale je nutné pro správné fungování poslední vrstvy. Více informací o konvolučních sítích, jejich strukturách, metodách, vrstvách a mnoho dalšího lze nalézt na internetu [47].

Konvoluční neuronové sítě mohou mít různé vrstvy. Některé jsou stejné jako u klasických neuronových sítí a některé jsou pro CNN typické. První takovou vrstvou je plně propojená vrstva [44], což je základní vrstva klasických neuronových



Obrázek 20: Ukázka maxpooling vrstvy (2x2) [48]

4.2 Nástroje strojového učení

Přestože existuje velké množství možností, jak natrénuvat funkční model, jedná se o snadný a dostupný proces. Ovšem je nutné správně definovat svůj cíl, zvolit vhodný typ učení, správně připravit vstupní data a v neposlední řadě vybrat programovací prostředí a jazyk.

⁴ V případě první vrstvy se pak data berou přímo z části vstupního obrázku.

4.2.1 Programovací jazyk Python

Python [49] je programovací jazyk, který byl vyvinut v USA roku 1991. Jedná se o open source projekt, tedy je zdarma a je kompatibilní s mnohými operačními systémy, což z něj dělá jeden z nejrozšířenějších programovacích jazyků. Python umožňuje také do kódu importovat knihovny. Knihovna obsahuje kód již někým napsaný, na který se lze jednoduše odkazovat ve vlastním kódu.

4.2.2 Knihovny TensorFlow a Keras

TensorFlow [50] je softwarová knihovna, nástroj pracující s umělou inteligencí. Knihovna je open source a byla vyvinuta a vydaná v roce 2015 společností Google. Knihovna umožňuje snazší trénování, tvorbu, zlepšování a kontrolu nad tvorbou modelu umělé inteligence.

Keras [51] je také open source knihovna, umožňující snadnější komunikaci a práci s knihovnou TensorFlow prvně vydanou roku 2015. Keras umožňuje snadnou tvorbu vrstev, používání aktivačních funkcí, získávání dat o struktuře sítě a v průběhu trénování také vyhodnocování úrovně modelu.

4.2.3 Editor Visual Studio Code

Visual Studio Code [52], zkráceně VS Code, je editor, umožňující psaní kódu v různých jazycích, lepší organizaci a přehlednost kódu a také hledání a opravování chyb ve zdrojovém kódu. Lze jej využít například ve formě aplikace. Tu lze propojit se službou GitHub.

4.2.4 Systém Git a GitHub

GitHub [53] může být chápán jako webová služba poskytující online úložiště, online programovací prostředí, webhosting a mnoho dalšího. GitHub se hojně používá na ukládání a sdílení kódu mezi vybranými spolupracovníky přes takzvané repozitáře, což jsou de facto sdílená úložiště. Velkou výhodou GitHubu je, že k ukládání používá verzovací systém Git [54], který sbírá a ukládá data o změnách provedených se soubory, nejčastěji zdrojovými kódy, a lze tedy zpětně vyvolat již smazaný obsah nebo zobrazit změnu souboru v čase.

5 KLASIFIKACE SLUNEČNÍCH SKVRN POMOCÍ AI

Jak už bylo řečeno, motivem práce bylo vytvořit konvoluční model, který dokáže na základě dosud nasbíraných dat úspěšně predikovat označení skupiny slunečních skvrn podle McIntoshova systémem. McIntoshova klasifikace jsme vybrali vybrána z několika důvodů. Prvním je, že Ondřejovská hvězdárna tento systém používá od roku 1992 a všechny její předchozí kresby reklassifikovala z Curyšského klasifikace do McIntoshova systému. Díky tomu jsme mohli použít 7170 kreseb z období od roku 1971 do 06. 10. 2023. K práci nám také hvězdárna poskytla elektronická data obsahující polohy a klasifikaci 56375 skvrn z období od 11. 1943 do 19. 10. 2023. Dalším důvodem vybrání této klasifikace je, že tento systém má 3 na sobě skoro nezávislé podklasifikace a je možné zkoumat úspěšnost na každé této skupině zvlášť. V neposlední řadě je možné říci i to, že tento systém je zatím nejdokonalejší při zohlednění jeho celosvětového používání, a naproti Mount Wilsonově klasifikaci používá vizuální data sbíraná a zpracovávaná velmi dlouhou dobou, a nikoliv data ze sofistikovanějších a kratší dobu používanějších magnetometrů.

Poté, co jsme adekvátně upravili vstupní kresby, jsme je mohli použít k natrénování modelu. Data jsme rozdělili do tří množin, 80 % dat jsme použili pro trénování, 10 % pro validaci a 10 % pro testování přesnosti modelu. V průběhu tvorby konvolučních sítí jsme vytvořili několik verzí datasetu a vyzkoušeli různé kombinace nastavitelných parametrů neuronové sítě. Celý tento proces, včetně úpravy kreseb, jsme programovali v programovacím jazyce Python skrze aplikaci Visual Studio Code, ke které jsme měli připojený GitHub repozitář tak, aby chom mohli práci průběžně ukládat na cloudové úložiště. Právě GitHub jsme zvolili, neboť kromě jednoduchého uživatelského rozhraní nabízí také možnost zobrazit historii jednotlivých souborů.

5.1 Vstupní data

K samotnému natrénování modelu byla potřebná vstupní data v podobě anotovaných skupin slunečních skvrn. V našem případě se jednalo o 14852 skupin skvrn, které byly extrahovány z 7292 kreseb ve formátu .jpg, které nám poskytla Hvězdárna Ondřejov, a rozřazeny do složek podle jejich klasifikace za pomocí digitalizovaných dat kreseb. Abychom získali vstupní data, které ukazuje OBRÁZEK, provedli jsme kroky popsané níže.

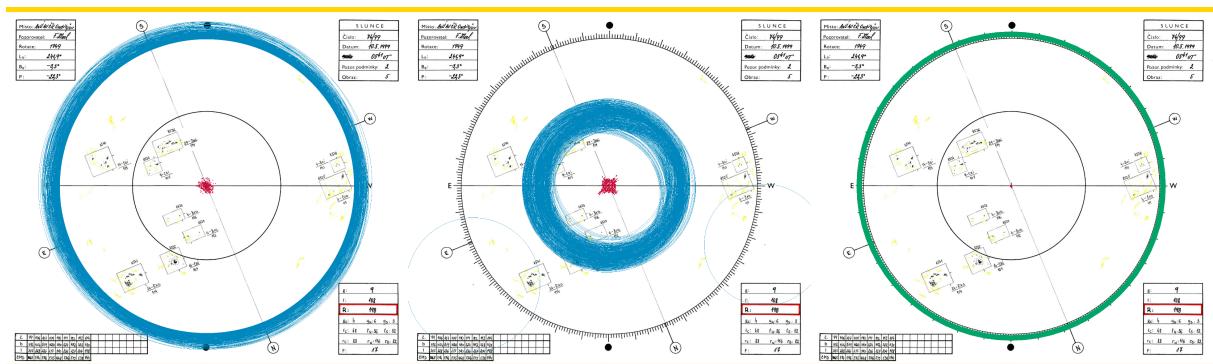


Obrázek 22: Vstupní data, na kterých jsme trénovali model; jedná se o skupinu Fsi

5.1.1 Úprava vstupní kresby

První úpravou, kterou jsme na vstupní kresbě provedli, bylo změnění její šířky na 2000 px a výšky ve stejném poměru. Tuto šířku jsme zvolili záměrně, neboť přibližně 99,4 % kreseb je právě 2000 px širokých, a tedy jsme s nimi nemuseli provádět žádnou úpravu, při které by došlo ke změně kvality. Zbylé kresby jsou většinou širší. Změna dimenzí všech obrázků na téměř stejné hodnoty je důležitá, neboť při trénování modelu chceme, aby měl správný pojem o relativní velikosti skupin na disku. Obrázek se změněnými dimenzemi jsme následně vložili na prázdné plátno velikosti 2000×1800 px. Tím jsme zajistili, že se s obrázkem v dalším kroku mohlo volně hýbat bez jeho podstatné části.

Dalším krokem jsme strojově detekovali obě pomocné kružnice, viz **Error! Reference source not found.**, našli jejich přesný střed (křížek na kresbě) a pomocí jeho aktuální polohy kresbu vystředili. Tím bylo zajištěno dostatečného znormování vstupních kreseb.

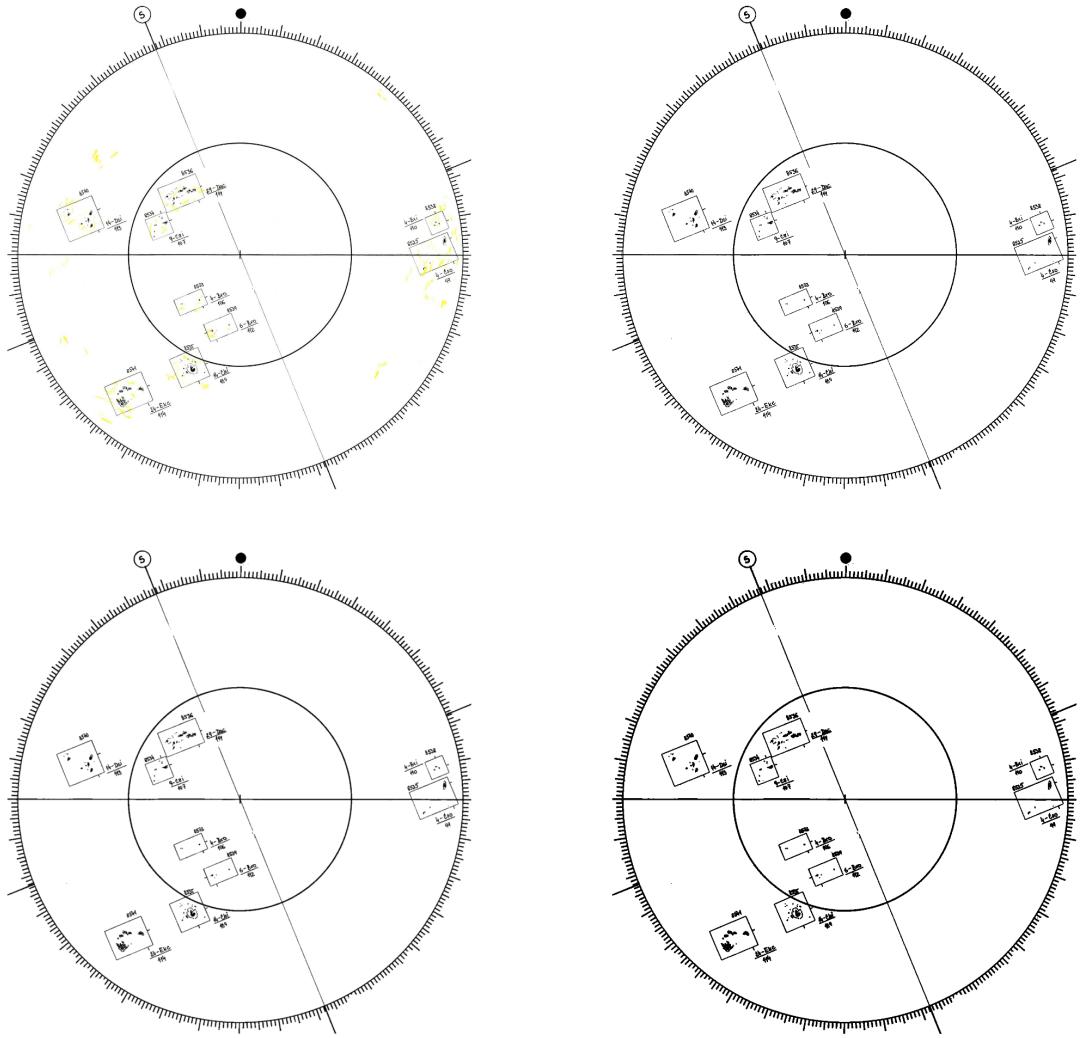


Obrázek 23: Příklad strojové detekce velké a malé pomocné kružnice; vlevo detekce velké kružnice s vyznačenými středy detekovaných kružnic, uprostřed stejná detekce malé kružnice, vpravo strojově odhadnutá poloha velké kružnice se středem

Posledním krokem před strojovým hledáním skupin byla aplikace masky, která zakryla tabulky v rozích protokolu, neboť by program detekoval i obdélníkové tabulky. Masku jsme ve volně dostupném obrázkovém editoru tak, aby co nejvíce zakrývala tabulky a co nejméně zasahovala do samotného zachycení Slunce.

5.2 Detekce čtyřúhelníků

Dalším krokem jsme vytvořili kopii zpracovávané kresby, na které jsme prováděli změny za účelem lepšího nalezení obdélníků. Důsledkem rozdílné kvality skenu a různého tlaku na tužku v průběhu kreslení kresby občas docházelo k tomu, že programem byla detekována pouze část ohraňujícího obdélníku. Abychom zkvalitnili proces detekce nahradili jsme každý pixel světlejší než (220, 220, 220) kompletně bílou barvou a pixel, který byl naopak tmavší, jsme nahradili kompletně černou barvou. Dále jsme na kopii aplikovali rozostření a opět pixely světlejší než (200, 200, 200) převedli na bílou a opačně. Tímto krokem jsme zajistili to, že pokud je čára v některém místě přerušena, případně zeslabena, dojde k jejímu spojení. Proces můžeme vidět pohledem na Obrázek 24.



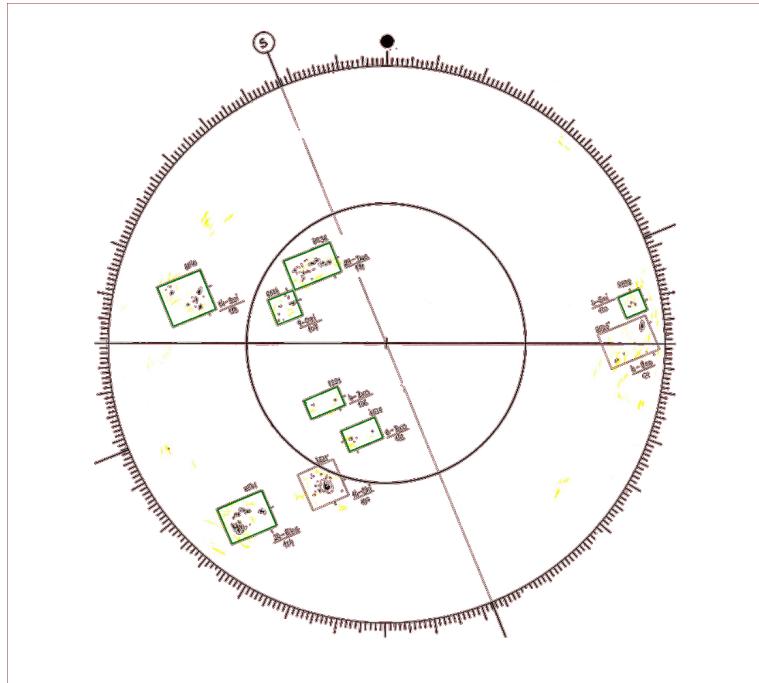
Obrázek 24: Proces úpravy kopie kresby za účelem zkvalitnění detekce; vlevo nahoře kresba s odebranými tabulkami, vpravo nahoře kresba po prvním nahrazování pixelů, vlevo dole kresba po rozostření, vpravo dole kresba po druhém nahrazování pixelů

Dále byly strojově nalezeny různé tvary na upravené kopii kresby a pokud tyto tvary měli čtyři rohy, jejich šířka i výška byla v rozmezí od 10 do 1 000 px, všechny sousedící strany byly na sebe kolmé a vzdálenost mezi všemi body byla větší než 28 px, tak byla vyříznuta oblast 300×300 px kolem středu nalezeného tvaru a uložena, viz Obrázek 26. Takto správně detekované tvary má Obrázek 25 označen zelenou barvou. Zároveň jsme také ukládali souřadnice rohů čtyřúhelníku do .csv tabulky tak, aby mohly být dále použity. Takto jsme vyextrahovaly 15 494 skupin.

5.3 Rozřazení dat podle klasifikace

Poté jsme pro každou kresbu na základě časového údaje vypočítali heliografická šířky a délky centra slunečního disku a úhel, o který je natočena rotační osa Slunce. Tyto údaje jsou taktéž uvedeny v protokolu kresby, ale je jednodušší je vypočítat, než je pomocí převodu obrázku na text, tzv. OCR [55], číst přímo z protokolu. Pro každou skupinu je také programem zjištěn úhel Q a vzdálenost skupiny od středu. Z těchto údajů je možné vypočítat heliografickou šířku a

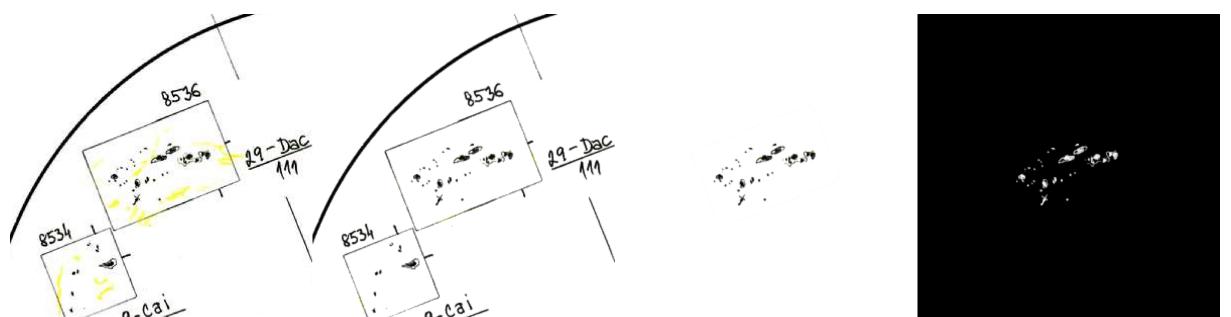
výšku skupiny skvrn a následně podle těchto údajů nalézt její klasifikaci v tabulce poskytnuté z Ondřejova. Takto jsme rozřadili 14852 skupin do složek s jejich klasifikacemi. Vznikla nám tedy struktura složek, které nesly jména McIntoshovy klasifikace a obsahovaly právě skupiny skvrn takto klasifikované.



Obrázek 25: Zeleně detekované skupiny skvrn, hnědě jiné detekované tvary

5.4 Příprava dat na trénování

Nejprve ze všeho byly programem vymazány duplicitní obrázky skupin, protože především u historických dat docházelo k tomu, že program detekoval jak vnější obdélník, tak i vnitřní obdélník ohraničující skupinu, a tedy skvrna byla uložena dvakrát. Pro zjednodušení fungování modelu jsme se rozhodli, že budeme pracovat s černobílým obrázkem. Poté byly programově odstraněny oranžovožluté části na obrázku (fakulová pole) a obrázek byl převeden na černobílý. Po případné ruční kontrole byla na skupinu aplikovaná bílá maska, která zakryla okolí skupiny a nechala pouze vnitřek obdélníku se skvrnou. Obrázek jsme poté invertovali, neboť model lépe pracoval s černým pozadím. Pohled na úpravu skupiny umožňuje Obrázek 26.



Obrázek 26: Úprava jednotlivých skupin skvrn do finální podoby, na kraji vlevo vyextrahovaná část 300×300 px kresby kolem detekované skupiny, vlevo uprostřed skupina po odebrání fakulových polí, vpravo uprostřed zakryté okolí skupiny, na kraji vpravo finální podoba skupiny

Poté jsme data nutná k tvorbě aktuálního modelu rozdělili do trénovacích, validačních a testovacích adresářů. Složku s nejmenším počtem dat jsme rozdělili na trénovací (80 %), validační (10 %) a testovací (10 %) datasety. Z ostatních složek jsme následně vzali stejný počet testovacích vzorků jako jsme měli z nejmenší složky. Zbylé obrázky jsme rozdělili v poměru 8:1 do trénovací, resp. validační složky. Toto nerovnoměrné rozložení datasetů jsme zvolili kvůli velké variabilitě počtu vzorků jednotlivých skupin. Každá třída tedy měla jiný počet vstupních dat v trénovací a validační složce, ale abychom zajistili nezkreslenou přesnost modelu tak testovací složka vždy obsahovala stejný počet skupin každé třídy. Vážení⁵ jednotlivých tříd jsme nakonec nepoužili, neboť modely bez vážení i s vážením dosahovali velmi podobných výsledků.

5.5 Architektura modelu

Když jsme měli požadovanou strukturu pro tvorbu konvoluční neuronové sítě připravenou, mohli jsme začít trénovat jednotlivé modely. Při trénování všech modelů jsme vhodně zvolili následující parametry.

1. *Batch size*: Počet vstupních dat připadajících na jeden proces zpětné propagace.
2. *Steps per epoch*: Kolik kroků učení model bude dělat mezi vyhodnocením své přesnosti na validačních datech.
3. *Validation steps*: Na kolika validačních obrázcích určí model svou přesnost.
4. Počet a strukturu vrstev: Vybrání počtu a typu vrstev, počtu neuronů v nich a aktivační funkce.

Model se v průběhu trénování ukládal a poté jsme za nejlepší model považovali ten, který měl nejnižší hodnotu loss funkce. Model jsme trénovali maximálně 300 epoch. Výsledky jsme vyhodnocovali na testovacích datech, tedy takových, ke kterým neměl model v průběhu trénování a validace přístup.

⁵ Vážení je zohlednění počtu vzorků v jednotlivých třídách. Model má sice k dispozici méně vstupních dat některé třídy, ale klade větší důraz, aby ji predikoval správně.

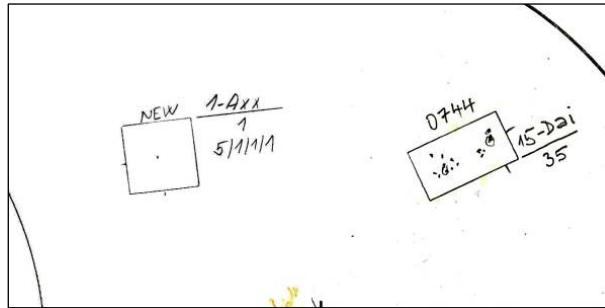
6 VÝSLEDKY PRÁCE

6.1 Klasifikace do dvou tříd

Obecně by měly být tyto modely velmi přesné, neboť se jedná o otázku bud' ta, nebo ta třída. Zároveň lze vybrat takové třídy, u kterých máme dostatek dat a mezi kterými jsou znatelné rozdíly. Další velkou výhodou je, že trénování méně tříd nepotřebuje výkonnou výpočetní techniku a tyto modely tedy lze jednoduše znova trénovat s různými parametry za krátký časový úsek.

6.1.1 Model Axx-Dai

Tento model měl být velmi přesný v rozhodování mezi skupinami typu Axx a Dai, protože rozdíl mezi oběma skupinami je markantní. Skupina Axx je osamocená malá skvrna, zatímco skupina Dai již obsahuje penumbry, je znatelně větší, a na rozdíl od skupiny Axx jsou skvrny rozloženy spíše u pólů skupiny než v jejím středu. Obě skupiny ukazuje Obrázek 27. Zároveň



Obrázek 27: Třídy modelu Axx-Dai

jsme měli řádově stovky snímků obou skupin, model měl více vstupních dat, což také přidává na přesnosti. Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 1: Vstupní data a parametry CNN modelu Axx-Dai

Počet tříd	Celkem vzorků	Počet vzorků v třídách Axx, Dai	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
2	2 499	1 668, 831	32	24	38	7

Detailní struktura modelu pak vypadala takto:

Tabulka 2: Struktura CNN modelu Axx-Dai

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	32	3×3	ReLU
2	Maxpooling		2×2	
3	Konvoluční	16	3×3	ReLU
4	Maxpooling		2×2	
5	Flatten			
6	Plně propojená	24		ReLU
7	Plně propojená	2		Softmax

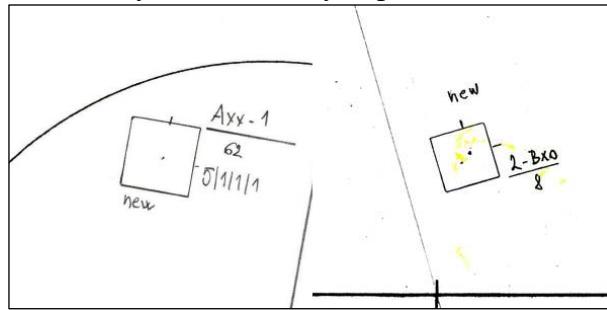
Touto kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 98,21 %
- Nejlepší epocha: 26
 - Hodnota validační loss funkce: 0,030498

Není divu, že se model naučil rozhodovat mezi třídami s téměř 100% přesností a za poměrně krátký čas, neboť byly vytvořeny ideální podmínky, tj. znatelná diverzita mezi třídami, velký počet⁶ vstupních dat a jednoduchá struktura.

6.1.2 Model Axx-Bxo

V porovnání s předchozím modelem Axx-Dai měl být tento model méně přesný, neboť skupiny Axx a Bxo se od sebe odlišují znatelně méně. Hlavním rozdílem mezi skupinami je, že skupina Axx je samotná skvrna, zatímco Bxo obsahuje více skvrn. Podobu obou tříd zobrazuje Obrázek 28. Tento fakt by se měla konvoluční neuronová síť relativně dobře naučit. Zároveň máme více dostupných dat z obou tříd, a to by také mělo zvýšit přesnost.



Obrázek 28: Třídy modelu Axx-Bxo

Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 3: Vstupní data a parametry CNN modelu Axx-Bxo

Počet tříd	Celkem vzorků	Počet vzorků v třídách Axx, Bxo	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
2	3 429	1 668, 1 761	32	20	60	5

Detailní struktura modelu pak vypadala takto:

Tabulka 4: Struktura CNN modelu Axx-Dai

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	16	3×3	ReLU
2	Maxpooling		2×2	
3	Flatten			
4	Plně propojená	16		ReLU
5	Plně propojená	2		Softmax

⁶ Je třeba poznamenat, že je myšleno v kontextu této práce. Standardní modely jsou obvykle trénovány na datasetech obsahujících řádově sto tisíc dat nebo dokonce více.

Touto kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 89,52 %
- Nejlepší epocha: 53
 - Hodnota validační loss funkce: 0,300535

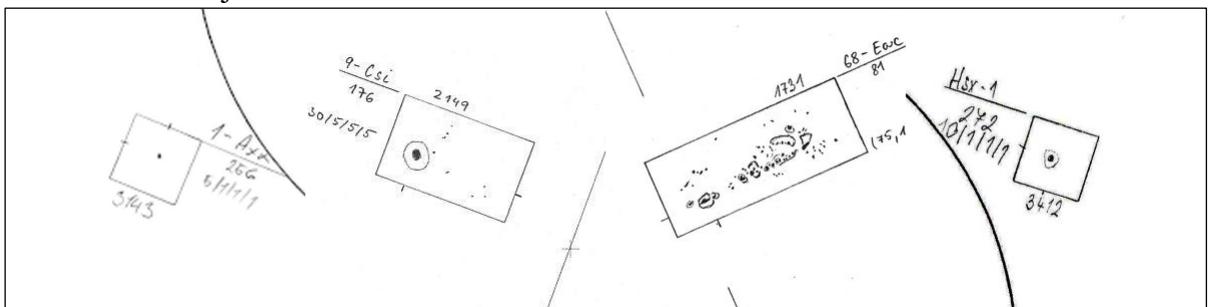
Je zřejmé, že se model naučil velmi dobře rozpoznávat obě kategorie. Zvýšit přesnost bychom mohli například přidáním více vrstev. Další možnosti, jak zlepšit výkon modelu, by bylo vstupní obrázky oříznout na menší velikost, neboť obě skupiny, jak Axx, tak Bxo, jsou relativně malé.

6.2 Klasifikace do čtyř tříd

Modely by měly pořád s velkou přesností zařadit skupinu do správné skupiny, zároveň by ale neměly být přesnější než modely dvou tříd, neboť přesnost s počtem tříd většinou klesá.

6.2.1 Model Axx-Csi-Eac-Hsx

Při tvorbě datasetu jsme záměrně vybrali 4 odlišně skupiny, a tudíž by neuronová síť měla tyto markantní rozdíly odhalit. Skupina Axx je pouze unipolární skvrna. Csi skupina obsahuje jen jednu skvrnu s penumbrou a další skupiny bez ní. Skupina Eac je nejkomplexnější z těchto dat, obsahuje jak skvrny s penumbrou, tak i bez penumbrou a rozložení skvrn je kompaktní. Skupina Hsx je taktéž unipolární skvrna jako skvrna Axx, ale na rozdíl je přítomna penumbra, což by měl model správně identifikovat. Ukázkou všech tříd obsahuje Obrázek 29. Je tedy pravděpodobné, že model bude spíše dělat chyby mezi skupinami Csi a Eac nebo Axx a Hsx, a nikoliv mezi jinými třídami, neboť právě tyto páry se od sebe nejméně, přesto ale velmi markantně odlišují.



Obrázek 29: Třídy modelu Axx-Csi-Eac-Hsx

Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 5: Vstupní data a parametry CNN modelu Axx-Csi-Eac-Hsx

Počet tříd	Celkem vzorků	Počet vzorků v třídách Axx, Csi, Eac, Hsx	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
4	3 991	1 668, 572, 206, 1 545	20	96	128	7

Detailní struktura modelu pak vypadala takto:

Tabulka 6: Struktura CNN modelu Axx-Csi-Eac-Hsx

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	32	4×4	ReLU
2	Maxpooling		3×3	
3	Konvoluční	16	3×3	ReLU
4	Maxpooling		2×2	
5	Flatten			
6	Plně propojená	32		ReLU
7	Plně propojená	4		Softmax

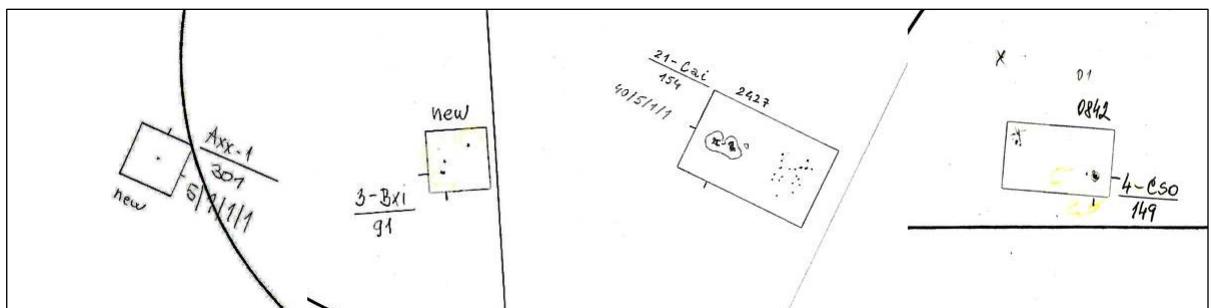
Touto kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 92,86%
- Nejlepší epocha: 46
 - Hodnota validační loss funkce: 0,219321

Model dokázala velmi přesně, s přesností blízkou 92 % predikovat jednotlivé třídy. Zároveň můžeme jasně sledovat korelaci počtu tříd a celkové, neboť model Axx-Dai dosáhl přesnosti 98,21 %. Obou těmto modelům jsme vybrali záměrně velmi odlišná vstupní data. Při tvorbě dalšího modelu by bylo dobré zamyslet se nad počtem kroků za epochu nebo nad hodnotou batch size, protože se model začal znatelně přetrénovávat již kolem 75 epochy, kde validační funkce dosahovala hodnot kolem 0,24.

6.2.2 Model Axx-Bxi-Cai-Cso

Model snažící se rozřadit skupiny slunečních skvrn do tříd Axx, Bxi, Cai a Cso má poměrně složitý úkol. Tyto třídy se od sebe na rozdíl od tříd předešlého modelu nijak výrazně neodlišují. Skupiny s prvním písmenem C mají skvrnu s penumbrou, což by se v ideálním případě měl model naučit. Rozdíl mezi skupinami Cso a Cai kromě tvaru penumbry spočívá v rozložení skvrn ve skupině, jedna skupina má rozložení otevřené a druhá přechodné, tj. skvrny se vyskytují i uprostřed skupiny. Skupina Bxi obsahuje skvrny pouze s umbrou rozloženou po celé její ploše. Skupina Axx je pouze jedna unipolární skvrna. Všechny skupiny ukazuje Parametry modelu jsme zvolili tak, aby se model trénoval a validoval po kratších úsecích. Měl by tedy nalézt přesněji minimum loss funkce. Zároveň jsme zvolili menší počet neuronů ve vrstvách, protože by jednoduchá neuronová síť mohla lépe provádět zpětnou propagaci.



Obrázek 30: Třídy modelu Axx-Bxi-Cai-Cso

Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 7: Vstupní data a parametry CNN modelu Axx-Bxi-Cai-Cso

Počet tříd	Celkem vzorků	Počet vzorků v třídách Axx, Bxi, Cai, Cso	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
4		1 668, 1 134, 662, 769	32	14	36	7

Detailní struktura modelu pak vypadala takto:

Tabulka 8: Struktura CNN modelu Axx-Bxi-Cai-Cso

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	16	4×4	ReLU
2	Maxpooling		3×3	
3	Konvoluční	8	3×3	ReLU
4	Maxpooling		2×2	
5	Flatten			
6	Plně propojená	32		ReLU
7	Plně propojená	4		Softmax

Touto kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 66,05 %
- Nejlepší epocha: 297
 - Hodnota validační loss funkce: 0,569998

Je zcela zřejmě, že s těmito vstupními daty si model nevedl tak dobře, jako v předchozích případech. Hlavním problémem jsou data samotná, která jsou si velmi podobná. Další překážku pro natrénování mohlo tvořit samotné nastavení neuronové sítě. Nejlepší epocha, která měla nejmenší hodnotu loss funkce, byla až 297. Model měl problém s nastavováním parametrů, neboť již v epoše 112 byla hodnota loss funkce pod 0,60, ale pořád oscilovala. Například v epoše 142 byla hodnota 0,644100. Toto značí špatnou schopnost modelu se učit. Pomohlo by zvýšit *steps per epoch*, případně i *learning rate*. Pohledem na konfuzní matici, viz Obrázek 31, můžeme zjistit, že skupina Axx byla predikována 65× dobře a pouze 2× špatně, ale třída Cso byla v přibližně polovině zaměněna za třídu Cai. Třídu Cai model pak stejnomořně zaměnil za třídu Bxi a Cso.

6.3 Finální model tříd

S vytvářením modelů o zvyšujícím počtu tříd bychom mohli zabrat mnoho dalších stran, ale věřím, že ten nejdůležitější model je ten, který by dokázal predikovat všechny třídy. Proto následující model obsahuje již skoro všechny třídy. Bohužel ale neobsahuje všechny třídy, protože například skupinu Fri jsme vůbec nedetekovali, nebo jsme měli pouze dva obrázky skupiny Eri. Nakonec jsme se rozhodli, že vytvoříme dataset z těch tříd, které mají alespoň 10 obrázků. Takto jsme museli vyloučit třídy Fri (0 obrázků), Fro (0), Fhi (0), Fho (1), Eri (2), Ero (3), Fso (3), Eho (5), Fao (8) a Fsc (8). Je patrné, že vyloučení se týkalo pouze E a F podtříd, neboť ty se celkově na slunečním disku vyskytují méně častěji než jiné skupiny. Finální model stavěný ze tříd tedy mohl rozhodovat pouze mezi 50 třídami. Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 9: Vstupní data a parametry CNN finální model tříd

Počet tříd	Celkem vzorků	Počet vzorků v třídách	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
50	14 709	Axx, Bxi, Bxo, Cai, Cao, Chi, Cho, Cki, Cko, Cri, Cro, Csi, Cso, Dac, Dai, Dao, Dhc, Dhi, Dho, Dkc, Dki, Dko, Dri, Dro, Dsc, Dsi, Dso, Eac, Eai, Eao, Ehc, Ehi, Ekc, Eki, Eko, Esc, Esi, Eso, Fac, Fai, Fhc, Fkc, Fki, Fko, Fsi, Hax, Hhx, Hkx, Hrx, Hsx 1 668, 1 134, 1 761, 662, 457, 48, 42, 64, 46, 410, 409, 572, 769, 458, 833, 306, 12, 38, 14, 196, 103, 38, 89, 59, 124, 337, 265, 206, 162, 22, 12, 18, 278, 124, 30, 59, 92, 33, 42, 23, 12, 180, 53, 11, 12, 426, 89, 58, 308, 1 545	32	32	54	9

Detailní struktura modelu pak vypadala takto:

Tabulka 10: Struktura CNN finálního modelu tříd

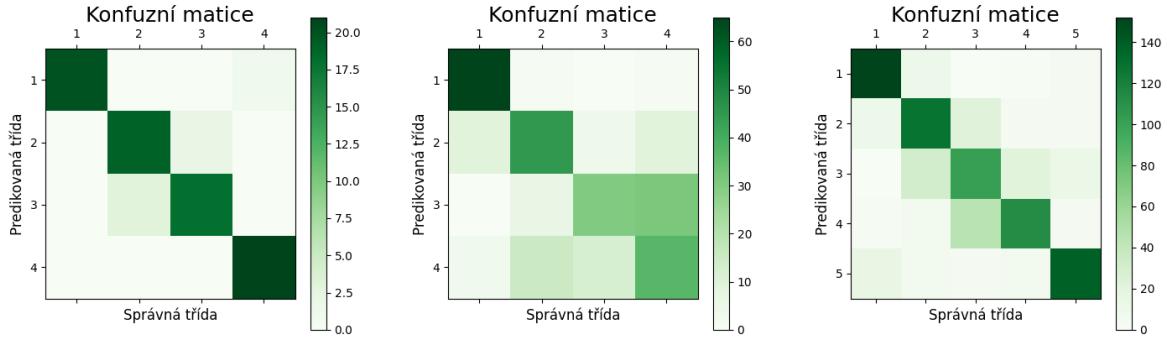
Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	64	4×4	ReLU
2	Maxpooling		3×3	
3	Konvoluční	32	3×3	ReLU
4	Maxpooling		2×2	
5	Konvoluční	16	2×2	ReLU
6	Maxpooling		2×2	
7	Flatten			
8	Plně propojená	96		ReLU
9	Plně propojená	50		Softmax

Touto kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 8,00 %
- Nejlepší epocha: 138
 - Hodnota validační loss funkce: 2,019897

Lze tedy s naprostou jistotou říci, že tento model nelze používat, neboť je velmi nepřesný. Pohledem na konfuzní matici i tak vidíme, že model měl snahu shlukovat všechna data na diagonálu, avšak vždy se mu to nepovedlo. Taktéž důkladnější analýzou, kde jsme si pomohli dalším programem můžeme zjistit, že první písmeno detekoval model správně v 45 % případů, druhé správně jen z 36 % a distribuci skvrn model zvládal na 46 %. I přestože tato čísla vypadají jako relativně úspěšná, nesmíme zapomenout, že kombinací těchto hodnot dostaneme celkovou přesnost jen 8 %. Tento příklad velmi názorně ukazuje, jak je důležité, aby i části modelu výsledné detekce byly přesné. Zamyslíme-li se nad tím, proč je celková přesnost celé číslo, zjistíme fakt, že od každé třídy máme pouze dvě testovací data, což je velmi málo. S tím souvisí i to, že z některých tříd budeme mít pouze kolem deseti trénovacích vzorků, což je velmi málo.

Rozhodnutí vyloučit třídy, které mají méně jak 10 vzorků se tedy jeví jako mírné. Model by tedy mohl fungovat, pokud bychom dokázali nashromáždit více vstupních dat.



Obrázek 31: Konfuzní matice vybraných modelů; vlevo modelu Axx-Csi-Eac-Hsx, uprostřed modelu Axx-Bxi-Cai-Cso, vpravo finálního modelu tříd

6.4 Klasifikace podle písmen

Jelikož jsme při tvorbě modelu ze vzorků tříd narazili na problém nedostatku dat konkrétních tříd nabízela se možnost natrénovat na každou podklasifikaci jiný model neuronové sítě. Tímto krokem dramaticky ubyde počet tříd, mezi kterými model predikuje, a také dramaticky přibyde množství vzorků v jednotlivých třídách. Datasetsy jsme tedy vytvářeli tak, že jsme vzali všechny skupiny s určitou podklasifikací a umístili je do stejné třídy, například při tvorbě modelu predikující první písmeno budou v třídě H všechny vzorky tříd Hax, Hhx, Hkx, Hrx, Hsx.

Také jsme v modelu pro první písmeno spojili klasifikační třídy D, E a F, neboť rozdíl mezi těmito klasifikacemi je pouze ve velikosti skupiny skvrn na Slunci. Neuronová síť v sobě ale nemá zabudovanou informaci o tom, zdali se aktivní oblast nachází ve středu slunečního disku, kde lze zanedbat zakřivení Slunce, nebo na okraji, kde dochází ke zploštění skvrny a tedy ztrátě informace o velikosti skupiny. Stejně tak jsme v případě druhého písmene spojili třídy s + h, a + k dohromady. Spojení tříd přineslo další vyrovnání počtu vzorků v jednotlivých třídách.

6.4.1 Model A-B-C-DEF-H

Tento model by neměl mít problém s klasifikací, neboť má k dispozici velké množství vstupních dat, klasifikuje do malého počtu tříd a rozdíly mezi třídami jsou velmi viditelné, viz Obrázek 9. Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 11: Vstupní data a parametry CNN modelu A-B-C-DEF-H

Počet tříd	Celkem vzorků	Počet vzorků v třídách A, B, C, DEF, H	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
5	14 768	1 668, 2 899, 3 483, 4 275, 2 443	32	28	56	9

Detailní struktura modelu pak vypadala takto:

Tabulka 12: Struktura CNN modelu A-B-C-DEF-H

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	32	3×3	ReLU
2	Maxpooling		3×3	
3	Konvoluční	16	2×2	ReLU
4	Maxpooling		2×2	
5	Konvoluční	8	2×2	ReLU
6	Maxpooling		2×2	
7	Flatten			
8	Plně propojená	32		ReLU
9	Plně propojená	5		Softmax

Touto kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 75,81 %
- Nejlepší epocha: 210
 - Hodnota validační loss funkce: 0,625329

Z výsledků je patrné, že model dosáhl poměrně obstojných výsledků. Svou přesností například překonal model Axx-Bxi-Cai-Cso. Přesnost modelu by se dala zlepšit vytvořením více vrstev konvoluční neuronové sítě a zvýšením počtu neuronů v jednotlivých vrstvách.

6.4.2 Model ak-r-sh-x

Dalo by se předpokládat, že model druhé podklasifikace bude méně přesnější než oba jiné modely, neboť tato podklasifikace referuje pouze na největší skvrnu, jejíž relativní poloha vůči skupině bývá vždy odlišná, a tedy nelze přesně říci, kde na obrázku je tato důležitá skvrna umístěna. Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 13: Vstupní data a parametry CNN modelu ak-r-sh-x

Počet tříd	Celkem vzorků	Počet vzorků v třídách ak, r, sh, x	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
4	14 768	4 802, 1 282, 4 115, 4 569	48	64	108	7

Detailní struktura modelu pak vypadala takto:

Tabulka 14: Struktura CNN modelu ak-r-sh-x

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	32	3×3	ReLU
2	Maxpooling		3×3	
3	Konvoluční	16	2×2	ReLU
4	Maxpooling		2×2	
5	Flatten			
6	Plně propojená	32		ReLU
7	Plně propojená	4		Softmax

Tento kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost: 61.24 %
- Nejlepší epocha: 262
 - Hodnota validační loss funkce: 0,716335

6.4.3 Model c-i-o-x

Dalo by se předpokládat, že model druhé podklasifikace bude méně přesnější než oba jiné modely, neboť tato podklasifikace referuje pouze na největší skvrnu, jejíž relativní poloha vůči skupině bývá vždy odlišná, a tedy nelze přesně říci, kde na obrázku je tato důležitá skvrna umístěna. Parametry konvoluční sítě jsme zvolili následovně:

Tabulka 15: Vstupní data a parametry CNN modelu c-i-o-x

Počet tříd	Celkem vzorků	Počet vzorků v třídách c, i, o, x	Batch size	Steps per epoch	Validation steps	Počet vrstev včetně výstupní
4	14 768	1 603, 4 776, 4 288, 4 101	56	72	108	7

Detailní struktura modelu pak vypadala takto:

Tabulka 16: Struktura CNN modelu c-i-o-x

Vrstva	Typ vrstvy	Počet neuronů	Velikost matice	Aktivační funkce
1	Konvoluční	16	3×3	ReLU
2	Maxpooling		3×3	
3	Konvoluční	8	2×2	ReLU
4	Maxpooling		2×2	
5	Flatten			
6	Plně propojená	32		ReLU
7	Plně propojená	4		Softmax

Tento kombinací parametrů jsme dostali tyto výsledky:

- Celková přesnost:
- Nejlepší epocha:
 - Hodnota validační loss funkce:

6.5 Finální model písmen

Nyní, když už máme k dispozici modely všech tří podklasifikací, můžeme je spojit v jednom kódu a nechat je samostatně predikovat každý svou podklasifikaci a až poté seskládat výsledný název skupiny.

7 ZÁVĚR

Výsledkem práce je průpravný text k tvorbě AI za účelem kategorizace skupin slunečních skvrn, dále pak postup, kterak vytvořit fungující model schopný kategorizovat do jednotlivých

tříd s použitím protokolu kresby Slunce i detailní popis tohoto postupu. Taktéž jsme v práci vytvořili osm modelů, každý schopný predikovat alespoň část McIntoshovy klasifikace.

7.1 Diskuze

Je důležité ale připomenout, že jsme třídy D, E a F spojili do jedné, a tedy by bylo ještě nutné vytvořit program, který ze souřadnic na kresbě

7.2 IMPLEMENTACE HVĚZDÁRNAMI

7.3 Chyby

Bohužel došlo k různým komplikacím při strojovém zpracovávání, a proto bylo možné vyextrahovat pouze 15494 skupin, což je přibližně 25 % všech skupin zaevidovaných elektronicky.

Hlavním důvodem ztráty tolka skupin bylo, že skupina, která leží poblíž vnitřní kružnice nebo OSY, je ohraničena obdélníkem, který protíná právě nějaká pomocná čára na kresbě, a tento obdélník už není detekovatelný programe, který byl vytvořen. Děje se tak, protože proces automaticky tvary rozdělí. Tento problém byl ponechán s možností řešení, neboť pro dokázání funkčnosti modelu není nutné tolik dat jako při důkladném trénování.

Další překážku, kterou bylo nutné v průběhu přípravy překonat, byla orientace kresby. Do 16. 08. 2012 se kresba kreslila se severem dolů, ale od tohoto data se celá o 180° otočila a sever byl nahoře. Toto otočení způsobovalo počítání souřadnic skupiny, neboť pro jejich výpočet je nutný úhel vzhledem k **severu**. Různou polohu severu jsme pak zohlednili v kódu, který počítal heliocentrické souřadnice.

Diskutabilním krokem při přípravě vstupních dat je opravování šírky kreseb dat na 2000 px. Při tomto kroku nutně dochází k ztrácení informací, které by mohli být potencionálně využity. Vzhledem k tomu, že se ale změna šírky týkala malého množství obrázků nebylo nutné se tímto problémem více zaobírat.

Mělo se dělat víc runů

8 TVORBA SS

Po správné identifikaci cíle bývá také dobré se zamyslet, jestli nelze problém řešit jednodušeji bez použití strojového učení. Zároveň je také dobré rozhodnout se, jaká přesnost se od modelu očekává. Nesmí být podceňovaná ani příprava vstupních dat. Vstupními dat mohou mít

v podstatě jakoukoliv podobu. Může se jednat o obrázky, soubory čísel, videa, audio, texty, velké databáze, dokumenty a mnohé další. Tato data by měla hlavně obsahovat relevantní informace a zanedbatelné množství chyb. Například místo barevných vstupních obrázků je dobré se zamyslet, jestli není výhodnější používat černobílé obrázky. Touto změnou pak místo třech barevných spekter bude model pracovat pouze s jedním, a tedy bude rychlejší.⁷ Poté, co jsou data připravená, je možné začít trénovat. K tomu je nutné mít vybraný styl trénování a prostředí. Při tvorbě chatovacího bota se může jednat o vybrání self-supervised learning, strukturu neuronové sítě obsahující 64 neuronových vrstev, se snižujícím počtem neuronů od 4096 lineárně do 128 s aktivační funkcí sigmoid v aplikaci VS Code programovacím jazykem Python. Po natrénování modelu je dobré zamyslet se nad efektivním určením jeho přesnosti. Jakmile je model dostatečně přesný, je připraven na masové využívání.

⁷ <https://www.techtarget.com/searchenterpriseai/feature/How-to-build-a-machine-learning-model-in-7-steps>

Pro jednotlivé části textu používejte tzv. styly. Když píšete nadpis, zvolte z nabídky Wordu styl Nadpis 1 (popř. Nadpis 2, Nadpis 3 pro nadpisy dalších úrovní, více než tři úrovně nadpisů byste používat neměli). Usnadní vám to automatické generování obsahu, ale také přispěje k jednotné grafické úpravě celé práce. Pro běžný text je použit styl Normální.

8.1 Nadpis 2. úrovně: Times New Roman, 16 b, tučný, mezera za 16 b

Pokud nevíte, jak pracovat se styly, jednoduše si zkopírujte vzorovou kapitolu 1., 2. nebo 3. úrovně a vložte si ji na patřičné místo svého textu. Původní (tyto) ukázkové texty pak přepište textem své práce SOČ.

8.1.1 Nadpis 3. úrovně: Times New Roman, 14 b, tučný, mezera za 14 b

Pokud nevíte, jak pracovat se styly, jednoduše si zkopírujte vzorovou kapitolu 1., 2. nebo 3. úrovně a vložte si ji na patřičné místo svého textu. Původní (tyto) ukázkové texty pak přepište textem své práce SOČ.

8.2 Parametry jednotlivých stylů

Pro popis tabulek a obrázků použijte styl Titulek, nebo lépe funkci Wordu Vložit titulek. Díky tomu snadno vytvoříte seznam tabulek nebo obrázků a navíc zajistíte, že budete mít tabulky a obrázky číslovány průběžně v celé práci SOČ. Ale pozor, číslování tabulek a obrázků je nezávislé! To tedy znamená, že budete mít Tabulku 1 i Obrázek 1, nikoliv Tabulku 1 a Obrázek 2, jak je zřejmé z následujících ukázek.

Tab. 1: Přehled parametrů jednotlivých stylů textu: Times New Roman, 100000 b

Styl	Písmo	Velikost	Další parametry
Nadpis 1	Times New Roman	18 b	Kapitálky, tučný řez, číslováno, mezera za 18 b
Nadpis 2	Times New Roman	16 b	Tučný řez, číslováno, mezera za 16 b
Nadpis 3	Times New Roman	14 b	Tučný řez, číslováno, mezera za 14 b
Normální	Times New Roman	12 b	12 b, řádkování 1,2, mezera za 12 b, zarovnání do bloku
Poznámka pod čarou ⁸ Titulek obrázku, tabulky	Times New Roman	10 b	
Bibliografický záZNAM	Times New Roman	12 b	Řádkování 1, zarovnání vlevo

⁸ V poznámce pod čarou můžete rozvést myšlenku do větších podrobností, které nejsou pro pochopení textu nezbytné. Poznámky pod čarou se číslují průběžně v celém textu. Uvádějí se vždy na stránce výskytu (tedy ne například na konci kapitoly nebo konci celé práce SOČ).



Obr. 1: Logo soutěže Středoškolská odborná činnost: Times New Roman, 10 b

Při tvorbě a popisu tabulek se řídte [zásadami](#) tvorby součástí odborných textů a prezentací.

8.3 Způsob citování

Všechny použité pasáže cizích prací musíte v textu výrazně označit (uvozovkami, nikoliv kurzívou) a opatřit bibliografickým odkazem. V seznamu literatury, který je uveden na konci práce, pak musí být veškerá použitá literatura uvedena v abecedním pořadí v souladu s normou ČSN ISO 690 (odkaz).

8.3.1 Odkazování v textu

Za každou cizí myšlenkou, kterou v textu použijete, musí být tzv. bibliografický odkaz. Nezáleží přitom na tom, jestli se jedná o přesný přepis pasáže textu (citace, označeno uvozovkami), nebo volné převyprávění myšlenek vašimi vlastními slovy (parafráze, bez uvozovek).

Existují tři přijatelné způsoby bibliografických odkazů, v celém textu ale musíte zachovat stejný způsob:

1. Uvedení jména, roku a strany použité literatury v kulatých závorkách (autor, rok, s. strana), tzv. Harvardský systém, tedy např.

Více k tématu citací naleznete v různých přehledných textech (Biernatová, Skúpa, 2011, 136).

Při tomto způsobu citování je seznam veškeré použité literatury uveden v abecedním pořadí podle prvního autora.

2. Uvedení čísla bibliografického odkazu, a to buď v hranaté závorce, nebo jako horní index, čísluje se vždy průběžně, tedy např.

Více o pravidlech tvorby dokumentů naleznete ve specializovaných monografiích [1].

Více o pravidlech tvorby dokumentů naleznete ve specializovaných monografiích.¹

Číslo se uvádí bezprostředně za slovem, pokud se odkaz týká tohoto slova, nebo až za větnou tečkou, pokud se odkaz týká obsahu celé věty.

Při tomto způsobu citování je seznam veškeré použité literatury seřazen podle pořadového čísla bibliografického odkazu v textu.

3. uvádění kompletního bibliografického záznamu v poznámce pod čarou

Záleží jen na vás, který způsob bibliografického odkazování použijete, správné jsou všechny tři. Doporučujeme ale, abyste se drželi citačních zvyklostí v oboru, ve kterém budete svou práci předkládat.

8.3.2 Bibliografický záznam

Podoba bibliografických záznamů odpovídá normě ČSN ISO 690. K jejich snadnému vytváření doporučujeme použít některý z citačních manažerů (např. www.citace.com, nebo katalogy knihoven (volte normu ČSN ISO 690), např. aleph22.nkp.cz.

Jednotlivé typy bibliografických záznamů se nedělí do více skupin (např. Internetové zdroje, Články, Knihy...), ale uvádějí v jednom neděleném seznamu.

8.4 Rozsah práce

Doporučený rozsah práce SOČ je 20–30 stran. Jedná se o takzvané normostrany, které mají rozsah 1 800 znaků včetně mezer. Do rozsahu práce se počítá pouze hlavní text práce, tzn. text od začátku kapitoly Úvod po konec kapitoly Závěr.

9 ZÁVĚR

Kapitola nazvaná povinně Závěr plní v práci SOČ dva úkoly. Za prvé musí stručně shrnout dosažené výsledky, což ovšem neznamená zopakování již dříve uvedených informací. Není potřeba znova vypočítávat všechny dílčí výsledky, kterých jste ve své práci dosáhli. Místo toho stručně zopakujte cíl práce formulovaný v Úvodu, a volně na něj navažte. Např. „V úvodu práce jsem si jako cíl vytvořila ověření čistoty studánek v okrese Bruntál. Tohoto cíle jsem dosáhla; zjistila jsem, že čistota studánek se ve srovnání s předchozím měřením zlepšila.“

Za druhé pak musí provést diskuzi dosažených výsledků. Formulujte také možné návaznosti práce jako inspiraci pro někoho, kdo by ve vaší činnosti chtěl pokračovat. V některých oborech je zvykem oddělit diskuzi do zvláštní kapitoly.

10 POUŽITÁ LITERATURA

- [1] Astronomická jednotka. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation, c2024 [cit. 2024-03-11]. Dostupné z: https://cs.wikipedia.org/w/index.php?title=Astronomick%C3%A1_jednotka&oldid=23683910
- [2] Solar radius. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation, c2024 [cit. 2024-03-11]. Dostupné z: https://en.wikipedia.org/w/index.php?title=Solar_radius&oldid=1210839025
- [3] Struktura Slunce. *POZOROVÁNÍ SLUNCE* [online]. [cit. 2024-03-12]. Dostupné z: <https://pozorovanislunce.eu/slunce/struktura-slunce.html>
- [4] The Sun. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation, c2024 [cit. 2024-03-12]. Dostupné z: https://upload.wikimedia.org/wikipedia/commons/thumb/d/d4/Sun_poster.svg/1024px-Sun_poster.svg.png
- [5] Slunce. *ALDEBARAN* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.aldebaran.cz/astrofyzika/sunsystem/slunce.php>
- [6] What are some historical observations of the Sun? *NSF NCAR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www2.hao.ucar.edu/education/about-the-sun/what-are-some-historical-observations-sun>
- [7] The Historical Sunspot Record. In: *Ice Core Records – From Volcanoes to Supernovas* [online]. [cit. 2024-03-14]. Dostupné z: https://chandra.harvard.edu/edu/formal/icecore/The_Historical_Sunspot_Record.pdf
- [8] Mehrere Sonnenfleckengruppen mit Umbra und Penumbra. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-14]. Dostupné z: <https://de.wikipedia.org/wiki/Sonnenfleck#/media/Datei:Sunspots.JPG>
- [9] Hvězdy – Sluneční skvrny. *Astronomia* [online]. c2024 [cit. 2024-03-14]. Dostupné z: <https://astronomia.zcu.cz/hvezdy/slunce/744-slunecni-skvrny>
- [10] Sunspot butterfly diagram. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-14]. Dostupné z: https://upload.wikimedia.org/wikipedia/commons/thumb/c/c4/Sunspot_butterfly_diagram.svg/800px-Sunspot_butterfly_diagram.svg.png
- [11] Sluneční skvrna. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-14]. Dostupné z: https://cs.wikipedia.org/wiki/Slune%C4%8Dn%C3%AD_skvrna

- [12] Sluneční cyklus. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-14]. Dostupné z: https://cs.wikipedia.org/wiki/Slune%C4%8Dn%C3%AD_cyklus
- [13] Sun magnetic field after omega effect. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-14]. Dostupné z: https://upload.wikimedia.org/wikipedia/commons/thumb/3/33/Sun%27s_magnetic_field_after_omega_effect.svg/768px-Sun%27s_magnetic_field_after_omega_effect.svg.png
- [14] Faculae and Sunspots at Solar Maximum. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-14]. Dostupné z: https://en.wikipedia.org/wiki/Solar_facula#/media/File:Faculae_and_Sunspots_at_Solar_Maximum.tif
- [15] Sluneční skvrna. *POZOROVÁNÍ SLUNCE* [online]. [cit. 2024-03-14]. Dostupné z: <https://pozorovanislunce.eu/vykladovy-slovnicek/slunejni-skvrna.html>
- [16] Graf slunečních cyklů. *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: https://www.asu.cas.cz/~sunwatch/public/files/Slunce/Grafy/graf_2009_2018/2018_SC_17-24.jpg
- [17] Minislovníček: Relativní číslo. *HVĚZDÁRNA V ROKYCANECH A PLZNI* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.hvr.cz/2011/09/26/minislovnicek-relativni-cislo/>
- [18] Relativní číslo slunečních skvrn. *POZOROVÁNÍ SLUNCE* [online]. [cit. 2024-03-14]. Dostupné z: <https://pozorovanislunce.eu/vykladovy-slovnicek/relativni-cislo-slunechnich-skvrn.html>
- [19] CARRASCO, V.M.S., L. LEFÈVRE, J.M. VAQUERO a M.C. GALLEGO. *Equivalence relations between the Cortie and Zürich sunspot group morphological classifications* [online]. 17 [cit. 2024-03-14]. Dostupné z: <https://arxiv.org/ftp/arxiv/papers/1503/1503.08724.pdf>
- [20] Examples of the Zuerich classification. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/public/files/other/clanky/2021/Examples-of-the-Zuerich-classification-of-sunspot-groups-source-Bray-and-Loughhead.jpg>
- [21] Beckovo číslo slunečních skvrn. *POZOROVÁNÍ SLUNCE* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.pozorovanislunce.eu/vykladovy-slovnicek/beckovo-cislo-slunechnich-skvrn.html>
- [22] McIntoshova klasifikace. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/public/files/other/clanky/zonnevlekclassificatie-1.jpg>

- [23] HILL, Rik, JENKINS, Jamey, ed. *Guidelines for the Observation of White Light Solar Phenomena* [online]. 3rd ed. 2010 [cit. 2024-03-14]. Dostupné z: https://www.alpo-astronomy.org/solarblog/wp-content/uploads/wl_2010.pdf
- [24] Tabulka CV index. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/public/files/other/clanky/2021/tabc.png>
- [25] PROJEKCE - ZÁKRES SLUNEČNÍ FOTOSFÉRY. *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/cs/stranka/kresba>
- [26] Graf CV index. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/public/files/other/clanky/2021/CV.png>
- [27] Kresba z 11. 04. 2022. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: https://www.asu.cas.cz/~sunwatch/new/www/public/files/archive_patrol/sunspot_drawings/2022/220411dr.jpg
- [28] Projekce. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/new/www/public/files/other/projekce.jpg>
- [29] Česlopol sbírá kresby Slunce. *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/new/www/cs/clanek/kresby>
- [30] Carringtonova rotace. *POZOROVÁNÍ SLUNCE* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.pozorovanislunce.eu/vykladovy-slovnicek/carringtonova-rotace.html>
- [31] Zjištění údajů z kresby. In: *Astronomický ústav AV ČR* [online]. [cit. 2024-03-14]. Dostupné z: <https://www.asu.cas.cz/~sunwatch/new/www/public/files/other/img40.png>
- [32] ChatGPT [online]. [cit. 2024-03-15]. Dostupné z: <https://chat.openai.com/>
- [33] DALL·E 2 [online]. © 2015–2024 [cit. 2024-03-15]. Dostupné z: <https://openai.com/dalle-2>
- [34] Strojové učení. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: https://cs.wikipedia.org/wiki/Strojov%C3%A9_u%C4%8Dení
- [35] Gemini [online]. [cit. 2024-03-15]. Dostupné z: <https://gemini.google.com/>
- [36] Colored neural network. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: [https://en.wikipedia.org/wiki/Neural_network_\(machine_learning\)#/media/File:Colored_neural_network.svg](https://en.wikipedia.org/wiki/Neural_network_(machine_learning)#/media/File:Colored_neural_network.svg)

- [37] Activation function. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: https://en.wikipedia.org/wiki/Activation_function
- [38] What is backpropagation really doing? In: *YouTube* [online]. [cit. 2024-03-15]. Dostupné z: <https://www.youtube.com/watch?v=Ilg3gGewQ5U>
- [39] JEŘÁBEK, Vladimír. *HLUBOKÉ NEURONOVÉ SÍTĚ PRO ROZPOZNÁNÍ TVÁŘÍ VE VIDEU* [online]. Brno, 2018 [cit. 2024-03-15]. Dostupné z: https://www.vut.cz/www_base/zav_prace_soubor_verejne.php?file_id=181536. Bakalářská práce. Vysoké učení technické v Brně.
- [40] *Underfitting, Overfitting* [online]. In: *SPRINGER NATURE*. [cit. 2024-03-15]. Dostupné z: https://media.springernature.com/full/springer-static/image/art%3A10.1007%2Fs13244-018-0639-9/MediaObjects/13244_2018_639_Fig9_HTML.png?as=webp
- [41] Training, validation, and test data sets. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: https://en.wikipedia.org/wiki/Training,_validation,_and_test_data_sets
- [42] Matice záměn. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: https://cs.wikipedia.org/wiki/Matice_z%C3%A1m%C4%9Bn
- [43] *Input, Kernel, Output* [online]. In: *imgbb*. [cit. 2024-03-15]. Dostupné z: <https://i.ibb.co/Lz5Zc0h/nagesh-cnn-intro-7.png>
- [44] DUBINA, Tomáš. *Využití neuronových sítí v BCI systémech založených na evokovaných potenciálech SSVEP* [online]. Plzeň, 2020 [cit. 2024-03-15]. Dostupné z: https://dspace5.zcu.cz/bitstream/11025/41804/1/Bakalarska_prace.pdf. Bakalářská práce. Západočeská univerzita v Plzni, Fakulta aplikovaných věd.
- [45] ZACHA, Jiří. *Konvoluční neuronové sítě pro klasifikaci objektů z LiDARových dat* [online]. Praha, 2019 [cit. 2024-03-15]. Dostupné z: https://dspace.cvut.cz/bitstream/handle/10467/82351/F3-BP-2019-Zacha-Jiri-Konvolucni_neuronove_site_pro_klasifikaci_objektu_z_LiDARovych_dat.pdf. Bakalářská práce. České vysoké učení technické v Praze.
- [46] KOLÁŘ, Tomáš. *Odhad pozice v těle pacienta ve snímcích získaných pomocí trojrozměrných zobrazovacích metod* [online]. Plzeň, 2017 [cit. 2024-03-15]. Dostupné z: <https://dspace5.zcu.cz/bitstream/11025/27100/1/d1.pdf>. Diplomová práce. Západočeská univerzita v Plzni, Fakulta aplikovaných věd.
- [47] Yamashita, R., Nishio, M., Do, R.K.G. et al. Convolutional neural networks: an overview and application in radiology. *Insights Imaging* 9, 611–629 (2018). <https://doi.org/10.1007/s13244-018-0639-9>

- [48] Max pooling. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: https://upload.wikimedia.org/wikipedia/commons/e/e9/Max_pooling.png
- [49] Python [online]. c2001-2024 [cit. 2024-03-15]. Dostupné z: <https://www.python.org/>
- [50] TensorFlow [online]. [cit. 2024-03-15]. Dostupné z: <https://www.tensorflow.org/>
- [51] Keras [online]. [cit. 2024-03-15]. Dostupné z: <https://keras.io/>
- [52] Visual Studio Code [online]. c2024 [cit. 2024-03-15]. Dostupné z: <https://code.visualstudio.com/>
- [53] GitHub [online]. c2024 [cit. 2024-03-15]. Dostupné z: <https://github.com/>
- [54] Git [online]. [cit. 2024-03-15]. Dostupné z: <https://git-scm.com/>
- [55] Optické rozpoznávání znaků. In: *Wikipedia: the free encyclopedia* [online]. San Francisco (CA): Wikimedia Foundation [cit. 2024-03-15]. Dostupné z: https://cs.wikipedia.org/wiki/Optick%C3%A9_rozpozn%C3%A1v%C3%A1n%C3%AD_znak%C5%AF
- [56]
- [57]
- [58]
- [59]
- [60]

BIERNÁTOVÁ, Olga, Jan SKŮPA. Bibliografické odkazy a citace dokumentů dle ČSN ISO 690 (01 0197) platné od 1. dubna 2011. [online]. c2004-2011 [cit. 2016-10-07]. Dostupné z: <http://citace.com/soubory/csniso690-interpretace.pdf>.

11 SEZNAM OBRÁZKŮ A TABULEK

Obr. 1: Logo soutěže Středoškolská odborná činnost: Times New Roman, 10 b41

Tab. 1: Přehled parametrů jednotlivých stylů textu: Times New Roman, 10 b.....40

12 PŘÍLOHA 1: NÁZEV PŘÍLOHY

Přílohy musí být průběžně číslovány. Do příloh můžete přesunout v podstatě cokoliv, co překračuje doporučený rozsah práce. Musíte ale pamatovat na to, že práce musí být srozumitelná i bez přečtení příloh.⁹ Celková délka příloh by neměla přesahovat 1/3 rozsahu hlavního textu práce.

⁹ Pokud do přílohy přesouváte plán či schéma, mělo by být v hlavním textu aspoň v blokové podobě. Totéž platí například pro výpis zdrojového kódu nebo návrh dotazníku.